



โครงการวิชา Practical Data Science

การตรวจตำแหน่งฟันผุด้วย Machine Learning

การจำแนกพื้นผิวฟันผุ (Dental Caries Surface Classification)

จัดทำโดย

นายนิรศ ผลภาค 6687025

นายพิชิตชัย แพเจริญชัย 6687033

นายศุกลภัทร ภิรักษ์เพ็ญ 6687052

อาจารย์ผู้สอน

ผศ. ดร. ศิริเพ็ญ พงษ์ไพเชฐ

ดร. สิริวิชญ เวชมนัส

โครงการนี้เป็นส่วนหนึ่งของรายวิชา ITDS346 Practical Data Science

หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิทยาการและเทคโนโลยีดิจิทัล

คณะเทคโนโลยีสารสนเทศและการสื่อสาร มหาวิทยาลัยมหิดล

ภาคการศึกษาที่ 2 ปีการศึกษา 2568

คำนำ (Preface)

รายงานฉบับนี้จัดทำขึ้นเป็นส่วนหนึ่งของรายวิชา ITDS346 Practical Data Science โดยมีวัตถุประสงค์เพื่อระบุพื้นที่มีรอยผุจากภาพ Panoramic Radiograph และจำแนกตำแหน่งพื้นผิวฟันผุ (Caries Surface Classification) ของฟันแต่ละซี่

โดยโครงการนี้มุ่งเน้นการพัฒนา **Hybrid Framework** สำหรับจำแนกตำแหน่งพื้นผิวฟันผุ (Dental Caries Surface Classification) จากภาพ Panoramic Radiograph ระบบประกอบด้วยการใช้ **Deep Learning** ในการตรวจจับฟัน (Tooth Detection) และแยกส่วนฟัน (Tooth Segmentation) ร่วมกับ **Rule-based Geometric Analysis** ในการจำแนกพื้นผิวฟันผุออกเป็น 3 ประเภทหลัก ได้แก่ Occlusal (ด้านบนเคี้ยว), Mesial (ด้านประชิดด้านหน้า) และ Distal (ด้านประชิดด้านหลัง)

ระบบที่พัฒนาขึ้นประกอบด้วยขั้นตอนหลักดังนี้ การจัดการข้อมูลภาพ Panoramic Radiograph, การวิเคราะห์โครงสร้างฟันระดับพิกเซล, การปรับแนวแกนฟันด้วยวิธีเชิงเรขาคณิต, การแบ่งโซนพื้นผิวฟัน (Surface Zoning), และการจำแนกตำแหน่งรอยผุภายในฟันแต่ละซี่ นอกจากนี้ ยังมีการประเมินผลโดยใช้กระบวนการทางสถิติ Bootstrap Resampling และ Two-Proportion Z-Test เพื่อวิเคราะห์ความแม่นยำ ความเสถียร และข้อจำกัดของแต่ละแนวทาง

คณะผู้จัดทำหวังว่ารายงานฉบับนี้จะเป็นประโยชน์ในการทำความเข้าใจการนำ Computer Vision และ Rule-based Data Science ไปประยุกต์ใช้กับงานทางการแพทย์ รวมถึงเป็นแนวทางสำหรับการพัฒนางานวิจัยที่เกี่ยวข้องในอนาคต

คณะผู้จัดทำ

สารบัญ (Table of Contents)

	หน้า
คำนำ (Preface)	ก
สารบัญ (Table of Contents)	ข
สารบัญภาพ (Table of Figure)	จ
สารบัญตาราง (Table of Tables)	ช
บทที่ 1 บทนำ	1
1.1 ที่มาของปัญหา	1
1.2 วัตถุประสงค์	1
1.3 ขอบเขตการทดลอง	2
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	4
2.1 โรคฟันผุและความสำคัญของการระบุตำแหน่งฟันผิวนัย	4
2.2 Panoramic Radiograph ทางทันตกรรม	5
2.3 ระบบหมายเลขฟัน FDI Notation	5
2.4 Deep Learning ในการวิเคราะห์ภาพทางการแพทย์	6
2.5 Convolutional Neural Network และ U-Net สำหรับ Image Segmentation	6
2.6 การตรวจจับฟันและการแยกส่วนฟัน	7
2.7 Principal Component Analysis สำหรับการวิเคราะห์แนวแกน	7
2.8 Rule-based Geometric Analysis และ Surface Zoning	8
2.9 สมการและตัวชี้วัดที่จำเป็นในการวิเคราะห์	8
2.9.1 การคำนวณจุดศูนย์กลางของ Mask	8
2.9.2 การคำนวณพื้นที่ซ้อนทับของ Mask	8
2.9.3 Principal Component Analysis สำหรับหาแนวแกนหลัก	9
2.9.4 การประเมินผลโมเดล	9
2.10 แหล่งโค้ดและเครื่องมืออ้างอิง	10
2.11 สรุป	11
บทที่ 3 การทดลอง	12
3.1 Dataset	12
3.1.1 การเก็บรวบรวมข้อมูลและแหล่งที่มา (Data Collection & Sources)	12

3.1.2 สถิติของชุดข้อมูลและการวิเคราะห์ข้อมูลเชิงสำรวจ (Dataset Statistics and Exploratory Data Analysis: EDA)	13
3.1.3 การเตรียมข้อมูล (Data Preparation)	18
3.2 การระบุพื้นที่ที่มีรอยผุ	19
3.3 การจำแนกด้านที่มีรอยผุ	20
3.3.1 PCA	21
3.3.2 Neighbor-Aware Orientation	22
3.3.3 Skeleton / Medial Axis	23
3.3.4 Surface Classification	25
3.4 การปรับปรุงกระบวนการจำแนกด้านที่มีรอยผุ	28
3.4.1 Improved PCA	28
3.4.2 Improved Surface Classification	28
บทที่ 4 ผลการทดลอง	31
4.1 ผลที่ได้จาก Dataset	31
4.2 ผลจากการระบุพื้นที่ที่มีรอยผุ	31
4.3 ผลจากจำแนกด้านที่มีรอยผุ	32
4.3.1 Method 1: Standard PCA (Baseline Model)	32
4.3.2 Method 2: Conditional Ratio	33
4.3.3 Method 3: Maximum Projected Span	34
4.3.4 Method 4: Split-Centroid Anatomy	35
4.3.5 Method 6: Absolute Vertical Prior	36
4.4 ผลจากการปรับปรุงกระบวนการจำแนกด้านที่มีรอยผุ	37
4.4.1 Method 8: X-Thirds Dominant Zone	37
4.4.2 Method 9: Diagonal-from-Centroid	38
4.5 ผลลัพธ์และการวิเคราะห์เชิงลึก	40
4.5.1 ประสิทธิภาพของแบบจำลอง (Overall Performance Summary)	41
4.5.2 การทดสอบสมมติฐานทางสถิติ (Statistical Hypothesis Testing)	41
4.5.3 การวิเคราะห์ข้อผิดพลาด (Error Analysis)	42
4.5.4 การวิเคราะห์สาเหตุหลัก (Root Cause Analysis)	42
4.5.5 การตัดสินใจเลือกแบบจำลองสุดท้าย (Final Model Decision)	43

บทที่ 5 บทสรุป	44
5.1 ข้อจำกัดและความท้าทายของโครงการ (Limitations & Challenges)	45
5.2 ข้อเสนอแนะและแนวทางการพัฒนาต่อ (Recommendations & Future Improvements)	45
บรรณานุกรม	47
ภาคผนวก	49

สารบัญภาพ

ภาพที่		หน้า
ภาพที่ 1	ตัวอย่างภาพ Panoramic Radiograph	1
ภาพที่ 2	ตัวอย่างพื้นผิวฟันโดยคำนึงถึง 3 พื้นผิวหลัก : Occlusal (ด้านบนเคี้ยว), Mesial (ด้าน ประชิดด้านหน้า) และ Distal (ด้านประชิดด้านหลัง)	2
ภาพที่ 3	Framework ที่แสดงการดำเนินงาน	2
ภาพที่ 4	ตัวอย่างภาพ Tooth Segmentation และ ROI Mask ฟันที่ระบุ Pixel ฟันผุและ Tooth ID	13
ภาพที่ 5	กราฟ Distribution ของจำนวนข้อมูลแต่ละคลาส (Occlusal / Mesial / Distal)	14
ภาพที่ 6	ตัวอย่างภาพ Bounding Box ที่มีลักษณะสูงตามแนวแกนรากฟัน	15
ภาพที่ 7	ตัวอย่างภาพ ฟันที่มีการคำนวณแกนผิดพลาด	15
ภาพที่ 8	ตัวอย่างภาพ Root Included in Mask ทำให้ Bounding Box สูงผิดสัดส่วน	16
ภาพที่ 9	ตัวอย่างภาพ ฟันที่มีการคำนวณแกนผิดพลาด	17
ภาพที่ 10	ตัวอย่างภาพ Incomplete Tooth Mask อาจส่งผลให้การแบ่งโซนคลาดเคลื่อน	17
ภาพที่ 11	Data Preparation ใช้ YOLO สำหรับการตรวจจับตำแหน่งฟัน (Tooth Detection) และ Detectron2 สำหรับการแยกส่วนฟันในระดับพิกเซล (Segmentation)	18
ภาพที่ 12	Caries-to-Tooth Mapping ใช้ ROI Mask ของรอยผุ และ การแยกส่วนฟันในระดับ พิกเซล (Segmentation) ในการ intersection เพื่อระบุ Pixel ฟันผุและ Tooth ID	19
ภาพที่ 13	ภาพ ROI Mask Overlap Visualization อธิบายการจับคู่รอยฟันผุกับฟัน	19
ภาพที่ 14	Overview ของ Spatial Reference System ที่แสดง Tooth Mask, Centroid และ PCA Axis	20
ภาพที่ 15	FDI Jaw Logic เพื่อใช้ในการจำแนกตำแหน่งขากรรไกรบนและล่าง	22
ภาพที่ 16	Neighbor-Aware Orientation แสดงผลลัพธ์ของการคำนวณ Centroid (จุดสีแดง) โดย ใช้แนวฟัน	23
ภาพที่ 17	Skeleton / Medial Axis ที่ Tooth mask แปลงเป็น Skeleton แสดงแกนที่ลากจาก รากไปตัวฟัน	24
ภาพที่ 18	ภาพ X-Thirds Dominant Zone เพื่อ เปรียบเทียบผลการแบ่งโซนทั้ง 2 วิธี X-Thirds vs Diagonal	29
ภาพที่ 19	ภาพ Diagonal-from-Centroid เส้นทแยงมุมผ่าน centroid และ พื้นที่สามเหลี่ยม	30

เพื่อ เปรียบเทียบผลการแบ่งโซนทั้ง 2 วิธี X-Thirds vs Diagonal

ภาพที่ 20	Classification Report ของ Method 1: Standard PCA (Baseline Model)	32
ภาพที่ 21	Evaluation ของ Method 1: Standard PCA (Baseline Model)	33
ภาพที่ 22	Classification Report ของ Method 2: Conditional Ratio Evaluation	33
ภาพที่ 23	Evaluation ของ Method 2: Conditional Ratio Evaluation	34
ภาพที่ 24	Classification Report ของ Method 3: Maximum Projected Span Evaluation	34
ภาพที่ 25	Evaluation ของ Method 3: Maximum Projected Span Evaluation	35
ภาพที่ 26	Classification Report ของ Method 4: Split-Centroid Anatomy Evaluation	35
ภาพที่ 27	Evaluation ของ Method 4: Split-Centroid Anatomy Evaluation	36
ภาพที่ 28	Classification Report ของ Method 6: Absolute Vertical Prior	36
ภาพที่ 29	Evaluation ของ Method 6: Absolute Vertical Prior	37
ภาพที่ 30	Classification Report ของ Method 8: X-Thirds Dominant Zone	38
ภาพที่ 31	Evaluation ของ Method 8: X-Thirds Dominant Zone	38
ภาพที่ 32	Classification Report ของ Method 9: X- Diagonal-from-Centroid	39
ภาพที่ 33	Evaluation ของ Method 9: X- Diagonal-from-Centroid	39
ภาพที่ 34	แสดง Best Framework หรือเส้นทางการดำเนินที่ดีที่สุดตั้งแต่ต้นถึงปลายทาง	45

สารบัญตาราง

ตารางที่		หน้า
ตารางที่ 1	Dataset Statistics Summary	13
ตารางที่ 2	ปัญหาที่พบในชุดข้อมูล	16
ตารางที่ 3	ตารางเปรียบเทียบผลลัพธ์กลุ่มแบบจำลองที่เน้นการปรับแนวแกนอ้างอิง (Axis Models)	40
ตารางที่ 4	กลุ่มแบบจำลองที่เน้นตรรกะการแบ่งพื้นที่ (Zoning Models)	40
ตารางที่ 5	เปรียบเทียบค่าความแม่นยำและค่า F1-score ของแบบจำลอง	41
ตารางที่ 6	สรุปงานวิจัยที่เกี่ยวข้อง	49

บทที่ 1

บทนำ

1.1 ที่มาของปัญหา (Problem Statement)

โรคฟันผุเป็นหนึ่งในปัญหาสุขภาพช่องปากที่พบได้บ่อยในทุกช่วงวัย โดยเฉพาะรอยผุที่เกิดบริเวณด้านบดเคี้ยวหรือบริเวณซอกฟัน ซึ่งมักตรวจพบได้ยากจากการตรวจด้วยสายตาเพียงอย่างเดียว ในปัจจุบันวิธีการมาตรฐานที่ใช้ในการตรวจหาฟันผุที่มองเห็นด้วยตาลำบาก การใช้ภาพ Bitewing Radiograph ซึ่งต้องอาศัยความชำนาญของนักรังสีเพื่อให้ได้ภาพที่มีคุณภาพ อีกทั้งยังอาจทำให้ผู้ป่วยไม่ได้รับความสะดวกสบาย


ดังนั้น การใช้ Panoramic Radiograph ดังตัวอย่างภาพที่ 1 จึงเป็นอีกทางเลือกหนึ่งที่สามารถเข้ามาแทนที่ได้ อย่างไรก็ตามการวิเคราะห์ภาพเอกซเรย์ยังคงต้องอาศัยประสบการณ์ของทันตแพทย์ เนื่องจากโครงสร้างของฟันมีความซับซ้อน ฟันแต่ละซี่มีแนวเอียงแตกต่างกัน และภาพอาจมีสัญญาณรบกวนจากเงากระดูก เหงือกหรือฟันซี่ข้างเคียง



ภาพที่ 1 ตัวอย่างภาพ Panoramic Radiograph

1.2 วัตถุประสงค์

- 1.2.1 เพื่อระบุฟันที่มีรอยผุจากภาพ Panoramic Radiograph
- 1.2.2 เพื่อจำแนกตำแหน่งพื้นผิวฟันผุ (Caries Surface Classification) ของฟันแต่ละซี่ (ภาพที่ 2)




ภาพที่ 2 ตัวอย่างพื้นผิวฟันโดยคำนึงถึง 3 พื้นผิวหลัก Occlusal (ด้านบดเคี้ยว), Mesial (ด้านประชิดด้านหน้า) และ Distal (ด้านประชิดด้านหลัง)

ภาพจาก [<https://www.dentalcare.com/en-us/ce-courses/ce500/surfaces-of-the-teeth>]

1.3 ขอบเขตการทดลอง

- 1.3.1 โครงการนี้ศึกษาการพัฒนาระบบสำหรับระบุตำแหน่งฟันและจำแนกพื้นผิวฟันจาก Panoramic Radiograph โดยใช้การตรวจจับฟัน การแยกส่วนฟัน และการวิเคราะห์แกนเชิงเรขาคณิต เพื่อจำแนกพื้นผิวฟันเป็น Occlusal, Mesial และ Distal
- 1.3.2 การศึกษาของโครงการเป็นการทดลองเชิงเทคนิคเท่านั้น และไม่ได้ถูกออกแบบมาเพื่อใช้แทนการวินิจฉัยทางคลินิกของทันตแพทย์โดยตรง แต่เป็นเพียงแนวทางในการพัฒนาเครื่องมือต้นแบบเพื่อช่วยทันตแพทย์ในการวิเคราะห์ข้อมูลฟันของคนไข้เบื้องต้นจาก Panoramic Radiograph เท่านั้น



ภาพที่ 3 Framework ที่แสดงการดำเนินงาน

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้นำเสนอทฤษฎี แนวคิด และงานวิจัยที่เกี่ยวข้องกับการจำแนกพื้นผิวฟันผุจากภาพ Panoramic Radiograph โดยครอบคลุมพื้นฐานด้านโรคฟันผุ ระบบหมายเลขฟัน FDI การใช้ Deep Learning ในการวิเคราะห์ภาพทางการแพทย์ การตรวจจับและแยกส่วนฟัน การใช้ Principal Component Analysis (PCA) เพื่อวิเคราะห์แนวแกนฟัน แนวทาง Rule-based Geometric Analysis และ Surface Zoning รวมถึงสมการและตัวชี้วัดที่จำเป็นในการวิเคราะห์ ตลอดจนงานวิจัยที่เกี่ยวข้องกับการตรวจจับและแยกส่วนฟันผุ

2.1 โรคฟันผุและความสำคัญของการระบุตำแหน่งพื้นผิวฟันผุ

โรคฟันผุเป็นปัญหาสุขภาพช่องปากที่พบได้บ่อยในประชากรทุกช่วงวัย เกิดจากกระบวนการทำลายแร่ธาตุของผิวฟันจากกรดที่เกิดจากเชื้อแบคทีเรียในคราบจุลินทรีย์ เมื่อรอยผุลุกลามมากขึ้นอาจส่งผลกระทบต่อเนื้อฟัน โพรงประสาทฟัน และนำไปสู่อาการปวด การติดเชื้อ หรือการสูญเสียฟันได้ การตรวจพบฟันผุตั้งแต่ระยะเริ่มต้นจึงมีความสำคัญต่อการวางแผนการรักษาและการป้องกันการลุกลามของโรค

ในการวิเคราะห์ทางทันตกรรม ตำแหน่งของรอยผุไม่ได้พิจารณาเพียงว่าฟันซี่ใดมีรอยผุเท่านั้น แต่ยังต้องระบุด้วยว่ารอยผุเกิดขึ้นบนพื้นผิวใดของฟัน เช่น ด้านบดเคี้ยว ด้านประชิดด้านหน้า หรือด้านประชิดด้านหลัง เนื่องจากพื้นผิวแต่ละตำแหน่งมีความสัมพันธ์กับลักษณะการเกิดโรค แนวทางการรักษา และความยากง่ายในการตรวจพบที่แตกต่างกัน งานคลาสสิกของ G. V. Black ได้วางพื้นฐานเกี่ยวกับการจำแนกและการจัดการรอยผุในงานทันตกรรมบูรณะ ซึ่งยังเป็นแนวคิดสำคัญต่อการทำความเข้าใจตำแหน่งและลักษณะของรอยผุในปัจจุบัน [1]

พื้นผิวของฟันที่เกี่ยวข้องกับการวิเคราะห์รอยผุสามารถแบ่งออกเป็นหลายบริเวณ โดยในงานวิเคราะห์พื้นผิวฟันผุมักให้ความสำคัญกับพื้นผิวหลัก ได้แก่ Occlusal หรือด้านบดเคี้ยว Mesial หรือด้านประชิดด้านหน้า และ Distal หรือด้านประชิดด้านหลัง การแยกตำแหน่งเหล่านี้มีความสำคัญ เนื่องจากรอยผุในแต่ละตำแหน่งมีลักษณะการตรวจพบและการรักษาที่แตกต่างกัน

2.2 Panoramic Radiograph ทางทันตกรรม

Panoramic Radiograph เป็นภาพถ่ายทางรังสีที่แสดงโครงสร้างฟัน ขากรรไกร และอวัยวะโดยรอบในภาพเดียว จึงถูกใช้เป็นเครื่องมือสำคัญในการตรวจประเมินสุขภาพช่องปากโดยรวม ภาพชนิดนี้ช่วยให้สามารถมองเห็นฟันหลายซี่พร้อมกัน เหมาะสำหรับการตรวจตำแหน่งฟัน ความผิดปกติของรากฟัน กระดูกขากรรไกร รวมถึงรอยโรคบางประเภท

อย่างไรก็ตาม Panoramic Radiograph มีข้อจำกัดด้านความละเอียด การซ้อนทับของโครงสร้าง และสัญญาณรบกวนจากเหงือก กระดูก หรือฟันข้างเคียง ทำให้การตรวจหาฟันผุ โดยเฉพาะรอยผุขนาดเล็กหรือรอยผุบริเวณซอกฟัน ยังเป็นงานที่ท้าทาย นอกจากนี้ แนวเอียงของฟัน รูปร่างฟันที่แตกต่างกันในแต่ละบุคคล และคุณภาพของภาพรังสี ยังส่งผลต่อความแม่นยำในการวิเคราะห์ตำแหน่งรอยผุด้วยระบบคอมพิวเตอร์

งานวิจัยด้าน Deep Learning หลายชิ้นจึงนำภาพ Panoramic Radiograph มาใช้เป็นข้อมูลนำเข้าสำหรับการตรวจจับและจำแนกรอยผุ เช่น งานของ Bui et al. ที่นำเสนอการสกัดคุณลักษณะเชิงลึกแบบ fusion สำหรับตรวจจับฟันผุจากภาพ Panoramic Radiograph [2] และงานของ Lian et al. ที่ใช้ Deep Learning สำหรับตรวจจับและจำแนกฟันผุในภาพ Panoramic Radiograph [3] นอกจากนี้ Asci et al. ยังศึกษาการแยกส่วนรอยผุโดยอัตโนมัติจากภาพ Panoramic Radiograph ในกลุ่มเด็ก [4] แสดงให้เห็นว่า Panoramic Radiograph สามารถนำมาใช้ร่วมกับเทคนิคปัญญาประดิษฐ์เพื่อพัฒนาระบบช่วยวิเคราะห์ทางทันตกรรมได้

2.3 ระบบหมายเลขฟัน FDI Notation

การระบุซี่ฟันอย่างเป็นมาตรฐานเป็นองค์ประกอบสำคัญของการวิเคราะห์ข้อมูลทางทันตกรรม โดยเฉพาะเมื่อต้องเชื่อมโยงรอยผุกับฟันแต่ละซี่ ระบบหมายเลขฟันที่ใช้กันอย่างแพร่หลายคือ FDI tooth numbering system [5] ซึ่งกำหนดหมายเลขฟันด้วยตัวเลขสองหลัก หลักแรกแทน quadrant หรือบริเวณของขากรรไกร และหลักที่สองแทนลำดับของฟันใน quadrant นั้น

ระบบ FDI notation ช่วยให้การระบุฟันแต่ละซี่มีความเป็นมาตรฐานและลดความสับสนในการสื่อสารข้อมูลทางทันตกรรม โดยเฉพาะเมื่อต้องวิเคราะห์ฟันจากภาพสองมิติ เช่น Panoramic Radiograph จากตำแหน่งของฟันบนขากรรไกรบนและล่าง รวมถึงด้านซ้ายและขวาของผู้ป่วย มีผลต่อการตีความทิศทาง Mesial และ Distal หากไม่มีระบบอ้างอิงที่ชัดเจน อาจทำให้การระบุด้านหน้าและด้านหลังของฟันเกิดความคลาดเคลื่อนได้

ดังนั้น FDI notation จึงเป็นระบบอ้างอิงสำคัญที่ช่วยให้การระบุ Tooth ID การจับคู่ข้อมูลรอยผุกับฟันแต่ละซี่ และการตีความทิศทางของฟันผุมีความสอดคล้องกับหลักทางทันตกรรมมากขึ้น

2.4 Deep Learning ในการวิเคราะห์ภาพทางการแพทย์

Deep Learning เป็นแขนงหนึ่งของ Machine Learning ที่ใช้โครงข่ายประสาทเทียมหลายชั้นในการเรียนรู้รูปแบบจากข้อมูลจำนวนมาก โดยเฉพาะข้อมูลภาพ งานสำรวจของ Litjens et al. และ Shen et al. ชี้ให้เห็นว่า Deep Learning มีบทบาทอย่างมากในงานวิเคราะห์ภาพทางการแพทย์ เช่น การจำแนกภาพ การตรวจจับวัตถุ และการแยกส่วนอวัยวะหรือรอยโรค [6], [7]

จุดเด่นของ Deep Learning คือสามารถเรียนรู้คุณลักษณะสำคัญจากภาพได้โดยอัตโนมัติ ลดความจำเป็นในการออกแบบคุณลักษณะด้วยมือเหมือนวิธี Machine Learning แบบดั้งเดิม ในงานภาพทางการแพทย์ เทคนิคดังกล่าวช่วยให้ระบบสามารถตรวจจับรูปแบบที่ซับซ้อนในภาพได้ เช่น ขอบเขตของอวัยวะ รอยโรค หรือความผิดปกติที่อาจสังเกตได้ยากด้วยตาเปล่า

ในงานทันตกรรม Deep Learning ถูกนำมาใช้ทั้งในการตรวจจับฟัน การระบุหมายเลขฟัน การตรวจหารอยผุ และการแยกส่วนรอยโรค งานของ Tuzoff et al. ใช้ Convolutional Neural Networks สำหรับการตรวจจับและระบุหมายเลขฟันในภาพ Panoramic Radiograph [8] ซึ่งสะท้อนให้เห็นว่า Deep Learning สามารถนำมาใช้เป็นพื้นฐานในการสร้างระบบช่วยวิเคราะห์ภาพทางทันตกรรมได้

2.5 Convolutional Neural Network และ U-Net สำหรับ Image Segmentation

Convolutional Neural Network หรือ CNN เป็นโครงข่ายประสาทเทียมที่เหมาะสมกับข้อมูลภาพ เนื่องจากใช้ convolutional layer ในการตรวจจับรูปแบบเฉพาะที่ เช่น ขอบ รูปร่าง พื้นผิว และลักษณะเชิงพื้นที่ของวัตถุ CNN จึงเป็นพื้นฐานสำคัญของโมเดล Deep Learning จำนวนมากที่ใช้ในงาน Computer Vision ทั้งการจำแนกภาพ การตรวจจับวัตถุ และการแยกส่วนภาพ

สำหรับงาน segmentation หรือการแยกส่วนภาพ โมเดลที่มีประสิทธิภาพสูงคือ U-Net ซึ่งพัฒนาโดย Ronneberger et al. สำหรับงาน biomedical image segmentation [9] จุดเด่นของ U-Net คือมีโครงสร้างแบบ encoder-decoder และ skip connection ทำให้สามารถรักษารายละเอียดเชิงพื้นที่ของภาพได้ดี จึงเหมาะกับงานแยกส่วนโครงสร้างทางการแพทย์ที่ต้องการความละเอียดระดับพิกเซล

ในงานด้านฟันผุ Bayrakdar et al. ได้นำ Deep Learning มาใช้ตรวจจับและแยกส่วนฟันผุจากภาพรังสี bitewing [10] ขณะที่ Asci et al. ศึกษาการแยกส่วนฟันผุอัตโนมัติจากภาพ Panoramic Radiograph [4] งานเหล่านี้แสดงให้เห็นว่า segmentation เป็นขั้นตอนสำคัญในการทำให้ระบบสามารถระบุตำแหน่งรอยผุได้ละเอียดกว่าการจำแนกภาพทั้งภาพเพียงอย่างเดียว

2.6 การตรวจจับฟันและการแยกส่วนฟัน

ก่อนที่จะสามารถวิเคราะห์ตำแหน่งของรอยผุได้ จำเป็นต้องทราบก่อนว่าฟันแต่ละซี่อยู่บริเวณใดในภาพ และรอยผุนั้นสัมพันธ์กับฟันซี่ใด งานด้าน tooth detection และ tooth segmentation จึงเป็นขั้นตอนพื้นฐานของระบบวิเคราะห์ภาพทางทันตกรรม

Tooth detection เป็นกระบวนการตรวจจับตำแหน่งของฟันแต่ละซี่ในภาพ โดยมักให้ผลลัพธ์เป็น bounding box หรือบริเวณที่คาดว่าเป็นตำแหน่งของฟัน ส่วน tooth segmentation เป็นกระบวนการแยกพื้นที่

ของฟันออกจากพื้นหลังหรือโครงสร้างอื่น ๆ ในภาพ โดยให้ผลลัพธ์เป็น mask ระดับพิกเซล ซึ่งมีประโยชน์ต่อการวิเคราะห์รูปร่าง ขอบเขต และตำแหน่งเชิงพื้นที่ของฟัน

Tuzoff et al. ใช้ CNN สำหรับ tooth detection และ numbering ในภาพ Panoramic Radiograph [8] รวมถึงงานวิจัยหลายชิ้นที่ใช้ Deep Learning เพื่อวิเคราะห์รอยผุจากภาพทางทันตกรรม [3]-[4], [10]-[11] งานเหล่านี้แสดงให้เห็นว่าการตรวจจับฟันและการแยกส่วนฟันเป็นขั้นตอนที่มีความสำคัญต่อการวิเคราะห์รอยผุในระดับละเอียด โดยเฉพาะเมื่อต้องเชื่อมโยงรอยผุกับฟันแต่ละซี่อย่างถูกต้อง

2.7 Principal Component Analysis สำหรับการวิเคราะห์แนวแกน

Principal Component Analysis หรือ PCA เป็นเทคนิคทางสถิติที่ใช้ลดมิติข้อมูลและวิเคราะห์ทิศทางการกระจายตัวหลักของข้อมูล โดยค้นหาแกนที่อธิบายความแปรปรวนของข้อมูลได้มากที่สุด Jolliffe และ Cadima อธิบายว่า PCA เป็นเครื่องมือสำคัญสำหรับการสรุปโครงสร้างข้อมูลเชิงหลายมิติ และมักถูกใช้ในการวิเคราะห์รูปแบบหรือทิศทางของข้อมูล [12]

ในงานวิเคราะห์ภาพ PCA สามารถนำมาใช้กับพิกัดของพิกเซลภายใน mask เพื่อประมาณแนวแกนหลักของวัตถุได้ โดย eigenvector ที่มี eigenvalue มากที่สุดจะแสดงทิศทางที่ข้อมูลมีการกระจายตัวมากที่สุด ซึ่งสามารถใช้เป็นแนวแกนหลักของวัตถุในภาพได้ แนวคิดนี้มีประโยชน์เมื่อวัตถุในภาพมีทิศทางหรือมุมเอียงแตกต่างกัน เพราะช่วยให้สามารถสร้างระบบอ้างอิงเชิงพื้นที่ที่สอดคล้องกันมากขึ้น

อย่างไรก็ตาม PCA มีข้อจำกัดในกรณีที่ mask มีสัญญาณรบกวน รูปร่างไม่สมบูรณ์ หรือมีส่วนเกินที่ไม่เกี่ยวข้องกับวัตถุที่ต้องการวิเคราะห์ เนื่องจากข้อมูลพิกเซลที่ผิดปกติอาจส่งผลต่อการคำนวณแนวแกนหลัก ทำให้แนวแกนที่ได้ไม่สอดคล้องกับโครงสร้างจริงของวัตถุ

2.8 Rule-based Geometric Analysis และ Surface Zoning

Rule-based Geometric Analysis เป็นแนวทางที่ใช้กฎเชิงเรขาคณิตในการตัดสินใจจากตำแหน่ง รูปร่าง ระยะทาง และความสัมพันธ์เชิงพื้นที่ของวัตถุ แนวทางนี้แตกต่างจากการใช้โมเดล Deep Learning แบบ end-to-end เพราะสามารถอธิบายเหตุผลของการตัดสินใจได้ชัดเจนกว่า และเหมาะกับงานที่ต้องการความโปร่งใสในการวิเคราะห์

Surface Zoning คือแนวคิดการแบ่งพื้นที่ของวัตถุออกเป็นโซนย่อยตามสมมติฐานเชิงพื้นที่หรือกายวิภาค เพื่อใช้วิเคราะห์ว่าตำแหน่งที่สนใจอยู่ในบริเวณใดของวัตถุ ตัวอย่างเช่น การแบ่งพื้นที่ออกเป็นบริเวณด้านซ้าย ด้านกลาง และด้านขวา หรือการแบ่งพื้นที่โดยใช้จุดศูนย์กลางและแนวแกนหลักเป็นตัวอ้างอิง

ในงานวิเคราะห์ฟัน การแบ่งโซนพื้นผิวสามารถใช้เพื่อแยกบริเวณที่สัมพันธ์กับด้านบดเคี้ยวและด้านประชิดของฟัน โดยอาศัยข้อมูลเชิงพื้นที่ เช่น centroid, bounding box, principal axis และตำแหน่งของ mask ภายในภาพ แนวทางนี้มีข้อดีคือสามารถอธิบายตรรกะการจำแนกได้ง่าย แต่มีข้อจำกัดเมื่อรูปร่างฟันมีความซับซ้อน หรือเมื่อข้อมูล segmentation มีความคลาดเคลื่อน

2.9 สมการและตัวชี้วัดที่จำเป็นในการวิเคราะห์

การวิเคราะห์ตำแหน่งรอยผุจากข้อมูลภาพจำเป็นต้องอาศัยสมการพื้นฐานบางส่วนเพื่อใช้ในการอธิบายขั้นตอนการคำนวณเชิงพื้นที่ ได้แก่ การหาจุดศูนย์กลางของ mask การคำนวณพื้นที่ซ้อนทับระหว่าง mask การหาแนวแกนหลักด้วย Principal Component Analysis และตัวชี้วัดสำหรับประเมินผลการจำแนกประเภท

2.9.1 การคำนวณจุดศูนย์กลางของ Mask

จุดศูนย์กลางหรือ centroid ใช้แทนตำแหน่งกึ่งกลางของพื้นที่ที่สนใจในภาพ เช่น tooth mask หรือบริเวณพิกเซลของฟัน หากกำหนดให้ mask หนึ่งประกอบด้วยพิกเซลจำนวน N จุด และแต่ละพิกเซลมีพิกัดเป็น (x_i, y_i) จุดศูนย์กลางสามารถคำนวณได้จากสมการ

$$C_x = \frac{1}{N} \sum_{i=1}^N x_i$$

$$C_y = \frac{1}{N} \sum_{i=1}^N y_i$$

โดย C_x และ C_y คือพิกัดของจุดศูนย์กลางในแนวแกน x และ y ตามลำดับ ค่า centroid มีประโยชน์ในการใช้เป็นจุดอ้างอิงสำหรับการวิเคราะห์ตำแหน่งภายใน mask และการแบ่งพื้นที่ออกเป็นโซนต่าง ๆ

2.9.2 การคำนวณพื้นที่ซ้อนทับของ Mask

ในงานวิเคราะห์ภาพระดับพิกเซล การตรวจสอบว่าพื้นที่สองบริเวณเกี่ยวข้องกันหรือไม่สามารถทำได้โดยการคำนวณพื้นที่ซ้อนทับของ mask หากกำหนดให้ M_c คือ mask ของรอยผุ และ M_t คือ mask ของฟัน พื้นที่ซ้อนทับสามารถคำนวณได้จากสมการ

$$Intersection = |M_c \cap M_t|$$

โดย $M_c \cap M_t$ หมายถึงพื้นที่พิกเซลที่เป็นทั้งส่วนของรอยผุและอยู่ภายใน mask ของฟัน ส่วน $|M_c \cap M_t|$ คือจำนวนพิกเซลที่ซ้อนทับกันระหว่าง mask ทั้งสอง ค่า intersection จึงใช้เพื่อบอกความสัมพันธ์เชิงพื้นที่ระหว่างรอยผุกับฟันแต่ละซี่

2.9.3 Principal Component Analysis สำหรับหาแนวแกนหลัก

Principal Component Analysis หรือ PCA เป็นวิธีทางสถิติที่ใช้หาทิศทางหลักของการกระจายตัวของข้อมูล โดยเริ่มจากการนำข้อมูลพิกัดพิกเซลมาจัดให้อยู่ในรูปเมทริกซ์ X และลบค่าเฉลี่ยออกจากข้อมูล จากนั้นคำนวณ covariance matrix ดังสมการ

$$\Sigma = \frac{1}{N-1} X^T X$$

โดย Σ คือ covariance matrix, X คือเมทริกซ์ข้อมูลผ่านการลบค่าเฉลี่ยแล้ว และ N คือจำนวนข้อมูลทั้งหมด จากนั้นหา eigenvalue และ eigenvector จากสมการ

$$\Sigma v = \lambda v$$

โดย v คือ eigenvector และ λ คือ eigenvalue โดยทั่วไป eigenvector ที่มีค่า eigenvalue มากที่สุดจะแสดงทิศทางที่ข้อมูลมีการกระจายตัวมากที่สุด จึงสามารถใช้เป็นแนวแกนหลักของวัตถุในภาพได้

2.9.4 การประเมินผลโมเดล

การประเมินผลระบบจำแนกประเภทสามารถพิจารณาจากค่าที่ได้จาก confusion matrix ได้แก่ True Positive (TP), False Positive (FP), False Negative (FN) และ True Negative (TN) ตัวชี้วัดที่ใช้ ได้แก่ Accuracy, Precision, Recall และ F1-score

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1-score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

ในกรณีที่เป็นการจำแนกหลายคลาส สามารถใช้ Macro F1-score เพื่อประเมินประสิทธิภาพโดยให้ความสำคัญกับทุกคลาสอย่างเท่าเทียมกัน

$$Macro\ F1 = \frac{1}{K} \sum_{i=1}^K F1_i$$

โดย K คือจำนวนคลาสทั้งหมด และ $F1_i$ คือค่า F1-score ของคลาสที่ i ค่า Macro F1-score เหมาะสำหรับกรณีที่ข้อมูลแต่ละคลาสมีจำนวนไม่เท่ากัน เพราะช่วยสะท้อนประสิทธิภาพของโมเดลในทุกคลาสได้ดีกว่าการพิจารณา Accuracy เพียงอย่างเดียว

ดังนั้นการประเมินผลโมเดลและปัญหา Class Imbalance จำเป็นต้องใช้ตัวชี้วัดหลายชนิดเพื่อสะท้อนประสิทธิภาพของโมเดลอย่างรอบด้าน ตัวชี้วัดที่ใช้ทั่วไป ได้แก่ Accuracy, Precision, Recall และ F1-score โดยเฉพาะในกรณีที่ชุดข้อมูลมีความไม่สมดุลระหว่างคลาส การพิจารณา Accuracy เพียงอย่างเดียวอาจทำให้เข้าใจผิดได้ เพราะโมเดลอาจทำนายคลาสที่มีจำนวนมากได้ดี แต่ทำนายคลาสที่มีจำนวนน้อยได้ไม่ดี Class Imbalance หรือความไม่สมดุลของข้อมูลระหว่างคลาส เป็นปัญหาที่พบได้บ่อยในงานจำแนกประเภท โดยเฉพาะเมื่อจำนวนตัวอย่างของแต่ละคลาสแตกต่างกันมาก หากโมเดลเรียนรู้จากข้อมูลที่มีคลาสใดคลาสหนึ่งมากกว่าคลาสอื่น โมเดลอาจมีแนวโน้มทำนายคลาสที่พบมากได้ดี แต่มีประสิทธิภาพต่ำในคลาสที่มีจำนวนตัวอย่างน้อยกว่า

เพราะฉะนั้น การประเมินผลจึงควรพิจารณาทั้งผลรวมของโมเดลและผลแยกรายคลาส โดยเฉพาะค่า Macro F1-score ซึ่งช่วยสะท้อนประสิทธิภาพของโมเดลต่อทุกคลาสอย่างเท่าเทียมกัน หากโมเดลมี Accuracy สูงแต่มี Macro F1-score ต่ำ อาจแสดงว่าโมเดลทำนายคลาสที่มีจำนวนมากได้ดี แต่ยังจำแนกคลาสที่มีจำนวนน้อยได้ไม่แม่นยำ

นอกจากนี้ Confusion Matrix ยังเป็นเครื่องมือสำคัญที่ช่วยให้เห็นรูปแบบความผิดพลาดของโมเดล เช่น โมเดลมักสับสนระหว่างคลาสใด หรือทำนายผิดไปเป็นคลาสใดบ่อยที่สุด ข้อมูลเหล่านี้มีประโยชน์ต่อการวิเคราะห์จุดอ่อนของระบบและการปรับปรุงวิธีจำแนกในขั้นตอนต่อไป

2.10 แหล่งโค้ดและเครื่องมืออ้างอิง

นอกจากบทความวิชาการแล้ว โครงการยังอ้างอิงแนวทางจาก repository ด้าน dental caries detection บน GitHub เพื่อเป็นแหล่งศึกษาการจัดโครงสร้างงาน การจัดการข้อมูล และการพัฒนา pipeline สำหรับการตรวจจับฟันผุ [13] อย่างไรก็ตาม การนำไปใช้ในโครงการต้องปรับให้เหมาะสมกับโจทย์การจำแนกฟันผุฟันผุและชนิดข้อมูลที่ใช้จริง

2.11 สรุป

จากการทบทวนงานวิจัย พบว่างานส่วนใหญ่ในปัจจุบันมุ่งเน้นไปที่การตรวจจับฟันผุหรือการแยกส่วนรอยผุจากภาพรังสีทางทันตกรรม โดยเฉพาะการระบุว่าบริเวณใดของภาพมีรอยผุ หรือฟันซี่ใดมีฟันผุ แต่ยังมีงานจำนวนน้อยที่มุ่งจำแนกตำแหน่งรอยผุในระดับพื้นผิวของฟันแต่ละซี่ โดยเฉพาะการจำแนกเป็น Occlusal, Mesial และ Distal จากภาพ Panoramic Radiograph ซึ่งมีความท้าทายสูงกว่าเนื่องจากภาพมีการซ้อนทับของโครงสร้างฟันมีแนวเอียงแตกต่างกัน และรอยผุอาจมีขนาดเล็กหรืออยู่ใกล้ขอบฟัน

โครงงานนี้จึงมีความแตกต่างจากงานวิจัยเดิมใน 3 ประเด็นหลัก

2.11.1 ประเด็นแรก คือ โครงงานไม่ได้หยุดอยู่ที่การตรวจจับรอยผุ แต่ต้องการจำแนกพื้นผิวของรอยผุในฟันแต่ละซี่

2.11.2 ประเด็นที่สอง คือ โครงงานใช้ผลลัพธ์จาก Deep Learning เช่น tooth detection และ tooth segmentation เป็นข้อมูลตั้งต้น แล้วนำมาวิเคราะห์ต่อยกด้วยกฎเชิงเรขาคณิต แทนที่จะใช้ Deep Learning จำแนกทุกขั้นตอนโดยตรง

2.11.3 ประเด็นที่สาม คือ โครงงานนำความรู้ทางกายวิภาคของฟัน เช่น FDI notation, tooth orientation และ surface zoning มาประกอบการตัดสินใจ ทำให้ระบบมีความสามารถในการอธิบายเหตุผลของการจำแนกได้มากขึ้น

ด้วยเหตุนี้ โครงงานจึงเป็นการต่อยอดจากงานวิจัยด้าน caries detection และ segmentation ไปสู่การวิเคราะห์เชิงตำแหน่งที่ละเอียดขึ้นในระดับพื้นผิวฟัน โดยใช้ Hybrid Framework ที่ผสาน Deep Learning กับ Rule-based Geometric Analysis เพื่อจำแนกตำแหน่งพื้นผิวฟันผุจากภาพ Panoramic Radiograph ให้เป็น Occlusal, Mesial และ Distal ซึ่งเป็นแนวทางที่เหมาะสมกับวัตถุประสงค์ของโครงงาน

บทที่ 3

การทดลอง

3.1 Dataset

ชุดข้อมูลที่ใช้ในการศึกษาของโครงการนี้ได้รับจากคณะทันตแพทยศาสตร์ มหาวิทยาลัยมหิดล โดยเป็นข้อมูลภาพ Panoramic Radiograph ร่วมกับไฟล์ Annotation รวมจำนวน 1979 จุดตัวอย่าง จาก 500 เคส ถูกใช้เป็นข้อมูลอ้างอิง (Ground Truth) สำหรับการวิเคราะห์และประเมินผลระบบ โดยชุดข้อมูลนี้ ใช้เพื่อศึกษาการระบุตำแหน่งฟันผิวด้านบนในระดัฟันแต่ละซี่ โดยข้อมูลในแต่ละเคสประกอบด้วยองค์ประกอบ สำคัญดังนี้

3.1.1 การเก็บรวบรวมข้อมูลและแหล่งที่มา (Data Collection & Sources)

3.1.1.1 ข้อมูลส่วนที่ได้รับมาจากคณะทันตแพทยศาสตร์ มหาวิทยาลัยมหิดล

3.1.1.1.1 ภาพ Panoramic Radiograph

เป็นภาพเอกซเรย์ระดับ grayscale ที่แสดงโครงสร้างฟันทั้งปาก ใช้เป็นข้อมูลนำเข้าสำหรับ กระบวนการตรวจจับฟัน (Tooth Detection) และการแยกส่วนฟัน (Tooth Segmentation)

3.1.1.1.2 ไฟล์ XML Annotation (Ground Truth XML Files)

เป็นไฟล์ข้อมูลเชิงโครงสร้างที่บันทึกข้อมูลอ้างอิงของแต่ละฟัน เช่น หมายเลขฟันตามระบบ FDI notation และตำแหน่งฟันผิวด้านบน ได้แก่ Occlusal, Mesial และ Distal ซึ่งใช้เป็นข้อมูล อ้างอิงสำหรับการประเมินผลลัพธ์ของระบบ

3.2.1.3 ROI Mask ของรอยผุ (Caries ROI Mask Grayscale Images)

ข้อมูลรอยผุไม่ได้ถูกระบุเป็นพิกัดโดยตรงภายในไฟล์ XML แต่ถูกจัดเก็บในรูปแบบภาพ Mask แยกต่างหาก โดยบริเวณที่มีค่า pixel มากกว่า 0 จะถูกตีความว่าเป็นพื้นที่ที่พบรอยผุ ระบบจะใช้ ROI Mask เหล่านี้ในการคำนวณพื้นที่ทับซ้อนระหว่างรอยผุกับฟันแต่ละซี่


3.1.1.2 ข้อมูลจากโมเดลต้นแบบ

3.1.1.2.1 ข้อมูล Segmentation ของฟัน (Tooth Segmentation Information)

ได้จากกระบวนการตรวจจับและแยกส่วนฟันด้วย YOLO และ Detectron2 ต้นแบบ ซึ่งให้ข้อมูล ทั้ง Bounding Box และ Pixel-Coordinate Mask ของฟันแต่ละซี่ เพื่อใช้ วิเคราะห์ตำแหน่งของรอยผุ

3.1.2 สถิติของชุดข้อมูลและการวิเคราะห์ข้อมูลเชิงสำรวจ (Dataset Statistics and Exploratory Data Analysis: EDA)

หลังจากกระบวนการตรวจจับและแยกส่วนฟันเพื่อให้ได้มาซึ่งฟันที่ระบุ Pixel ฟันผุและ Tooth ID เสร็จสิ้นดังตัวอย่างในภาพที่ 4 จะทำการวิเคราะห์ลักษณะของชุดข้อมูล (Exploratory Data Analysis: EDA) เพื่อ ศึกษาการกระจายตัวของข้อมูล ปัญหาความไม่สมดุลของคลาส (Class Imbalance) และลักษณะเชิงพื้นที่ของรอย ผุ ก่อนนำข้อมูลเข้าสู่กระบวนการวิเคราะห์เชิงเรขาคณิตและการประเมินผลโมเดล ชุดข้อมูลที่ใช้ในการประเมิน ประกอบด้วยตัวอย่างทั้งหมดจำนวน 1,979 ตัวอย่าง ซึ่งแต่ละตัวอย่างแทนฟันที่มีรอยผุและสามารถระบุฟันผุได้ โดยแบ่งออกเป็น 3 คลาสหลัก ได้แก่ Occlusal, Mesial และ Distal พบว่าการกระจายตัวของข้อมูลมีความไม่ สมดุลอย่างชัดเจนแสดงในตารางที่ 1




ภาพที่ 4 ตัวอย่างภาพ Tooth Segmentation และ ROI Mask ฟันที่ระบุ Pixel ฟันผุและ Tooth ID

ตารางที่ 1: Dataset Statistics Summary

Class	จำนวนตัวอย่าง	Percentage
Occlusal	388	19.60%


Mesial	670	33.86%
Distal	921	46.54%
Total	1979	100%

เมื่อพิจารณารูป Distribution ของจำนวนข้อมูลแต่ละคลาสดังตัวอย่างในภาพที่ 5 พบว่าชุดข้อมูลมีแนวโน้มเอนเอียงไปยังรอยผุบริเวณด้านข้างของฟัน (Mesial/Distal) มากกว่ารอยผุบริเวณด้านบดเคี้ยว (Occlusal) ซึ่งส่งผลโดยตรงต่อพฤติกรรมของโมเดล โดยโมเดลมักเรียนรู้หรือให้ความสำคัญกับคลาสขนาดใหญ่ได้ดีกว่า ขณะที่คลาส Occlusal ซึ่งมีจำนวนน้อยกว่าและมีลักษณะรูปร่างซับซ้อน อาจถูกจำแนกได้ยากกว่าอย่างชัดเจน




ภาพที่ 5 กราฟ Distribution ของจำนวนข้อมูลแต่ละคลาส (Occlusal / Mesial / Distal)

นอกจากนี้ จากการวิเคราะห์ลักษณะของภาพ Segmentation (ภาพที่ 4) พบว่ารูปร่างของ Bounding Box (ภาพที่ 6) ของฟันส่วนใหญ่มีลักษณะ “สูงตามแนวแกนรากฟัน” เนื่องจาก Mask ของฟันยังรวมส่วนรากฟัน (Root) อยู่ภายในภาพ ส่งผลให้การวิเคราะห์เชิงเรขาคณิตบางรูปแบบ เช่น การแบ่งพื้นที่ด้วยเส้นทแยงมุม (Diagonal-based Zoning) เกิดการบิดเบือนของสัดส่วนพื้นที่ด้านบนและด้านข้างของฟัน ซึ่งกลายเป็นหนึ่งในปัจจัยสำคัญที่ทำให้เกิดความคลาดเคลื่อนในการจำแนกฟันผุ



ภาพที่ 6 ตัวอย่าง Bounding Box ที่มีลักษณะสูงตามแนวแกนรากฟัน

ทั้งนี้ยังพบว่าข้อมูลด้านคุณภาพข้อมูลส่งผลต่อการวิเคราะห์ข้อมูลคลาดเคลื่อนเนื่องจากสาเหตุหลักดังแสดงในตารางที่ 2 ซึ่งสาเหตุที่พบคือ ความไม่สมบูรณ์ของ Tooth Segmentation ในบางภาพ ฟันบางซี่ถูกตัดขอบไม่ครบ มีการซ้อนทับของฟันข้างเคียง หรือมีสัญญาณรบกวนจากเหงือกและโครงสร้างกระดูก ซึ่งส่งผลให้การคำนวณแนวแกนของฟันด้วย PCA มีโอกาสเกิดความคลาดเคลื่อน โดยเฉพาะในฟันกรามที่มีความสมมาตรสูง เช่น ภาพที่ 7 แสดงภาพฟันที่มีการคำนวณแกนผิดพลาด




ภาพที่ 7 ตัวอย่างภาพ ฟันที่มีการคำนวณแกนผิดพลาด


เส้นสีแดงแสดง แกนฟัน และเส้นสีฟ้าแสดง ทิศทางการหมุน

ตารางที่ 2: ปัญหาที่พบในชุดข้อมูล


ปัญหา	ผลกระทบ
Class Imbalance	โมเดลทำนายคลาส Occlusal แม่นยำต่ำกว่าคลาสอื่น
Segmentation Noise	PCA คำนวณเกินขีด (ภาพที่ 6)
Root Included in Mask	Bounding Box สูงผิดสัดส่วน (ภาพที่ 8)
Tooth Overlapping	พื้นที่รอยผู้ซ้อนผิดชี (ภาพที่ 9)
Incomplete Tooth Mask	อาจส่งผลให้การแบ่งโซนคลาดเคลื่อน (ภาพที่ 10)



ภาพที่ 8 ตัวอย่างภาพ Root Included in Mask ทำให้ Bounding Box สูงผิดสัดส่วน



ภาพที่ 9 ตัวอย่างภาพ Tooth Overlapping พื้นที่รอยผู้ซ้อนผิดซี่




ภาพที่ 10 ตัวอย่างภาพ Incomplete Tooth Mask อาจส่งผลให้การแบ่งโซนคลาดเคลื่อน

จากผลการวิเคราะห์ดังกล่าว จึงเลือกใช้ตัวชี้วัดหลายรูปแบบในการประเมินผล ได้แก่ Accuracy, Precision, Recall และ Macro F1-Score เพื่อหลีกเลี่ยงอคติจากปัญหา Data Imbalance และสะท้อนประสิทธิภาพของโมเดลในทุกคลาสอย่างสมดุลมากขึ้น โดยเฉพาะคลาส Occlusal ซึ่งเป็นคลาสที่ตรวจจับได้ยากที่สุดในชุดข้อมูลนี้

3.1.3 การเตรียมข้อมูล (Data Preparation)

ในขั้นตอนนี้ เป็นการศึกษาลักษณะของข้อมูลภาพทางทันตกรรม โครงสร้างของไฟล์ Annotation และความสัมพันธ์ระหว่างข้อมูลจากหลายแหล่ง เพื่อให้สามารถนำข้อมูลเข้าสู่กระบวนการวิเคราะห์ได้อย่างถูกต้องและสอดคล้องกันภายใน Framework ของระบบ

กระบวนการเริ่มต้นจากการนำภาพ Panoramic Radiograph เข้าสู่ระบบเพื่อทำการตรวจจับและแยกส่วนฟันแต่ละซี่ โดยใช้โมเดล Computer Vision จำนวน 2 ส่วนร่วมกัน ได้แก่ YOLO สำหรับการตรวจจับตำแหน่งฟัน (Tooth Detection) และ Detectron2 สำหรับการแยกส่วนฟันในระดับพิกเซล (Segmentation) ดังแสดงในภาพที่ 11



ภาพที่ 11 Data Preparation ใช้ YOLO สำหรับการตรวจจับตำแหน่งฟัน

(Tooth Detection) และ Detectron2 สำหรับการแยกส่วนฟันในระดับพิกเซล (Segmentation)


โมเดล YOLO จะทำหน้าที่ตรวจจับตำแหน่งของฟันแต่ละซี่ภายในภาพ พร้อมสร้าง Bounding Box และกำหนดหมายเลขฟันตามระบบ FDI Notation เพื่อใช้เป็นข้อมูลอ้างอิงของฟันแต่ละซี่ภายในระบบ หลังจากนั้น

Bounding Box ของฟันแต่ละซี่จะถูกส่งเข้าสู่โมเดล Detectron2 เพื่อสร้าง Pixel-Coordinate Mask ของฟันแต่ละซี่อย่างละเอียด ซึ่งช่วยให้ระบบสามารถวิเคราะห์รูปร่าง แนวแกน และตำแหน่งเชิงพื้นที่ของรอยผุได้แม่นยำมากขึ้น


3.2 การระบุซี่ฟันที่มีรอยผุ

เมื่อได้ผลลัพธ์จาก Tooth Segmentation แล้ว จะนำมาใช้กับ ROI Mask ของรอยผุ เพื่อจับคู่ข้อมูลระหว่างฟันแต่ละซี่กับบริเวณรอยผุ โดยการใช้การคำนวณพื้นที่ซ้อนทับของพิกเซล (Intersection) เพื่อระบุว่าฟันซี่ใดมีรอยผุ และรอยผุนั้นกระจายตัวอยู่บริเวณใดของฟันดังตัวอย่างในภาพที่ 12 ก่อนส่งต่อเข้าสู่กระบวนการวิเคราะห์เชิงเรขาคณิตและการแบ่งโซนพื้นผิวฟันเพื่อระบุ Pixel ฟันผุและ Tooth ID ต่อไป

Step2: Caries-to-Tooth Mapping



ภาพที่ 12 Caries-to-Tooth Mapping ใช้ ROI Mask ของรอยผุ และ การแยกส่วนฟันในระดับพิกเซล (Segmentation) ในการ intersection เพื่อระบุ Pixel ฟันผุและ Tooth ID




ภาพที่ 13 ภาพ ROI Mask Overlap Visualization อธิบายการจับคู่อรอยฟันผุกับฟัน

3.3 การจำแนกด้านที่มีรอยผุ

หลังจากใช้การแสดงผลข้อมูลและภาพวิเคราะห์ต่าง ๆ เพื่อทำความเข้าใจพฤติกรรมของข้อมูลและปัญหาที่เกิดขึ้นในขั้นตอนการเตรียมข้อมูลแล้ว จะทำการนำผลจากการวิเคราะห์ภาพเหล่านี้ไปสู่การออกแบบระบบการแบ่งโซนพื้นผิวฟันเพื่อสร้างกรอบอ้างอิงเชิงพื้นที่ (Tooth Spatial Reference System) ที่เหมาะสมกับลักษณะของฟันแต่ละซี่

ในโครงการนี้ไม่ได้ใช้การสร้างคุณลักษณะ (Feature Extraction) ในลักษณะของ Machine Learning แบบดั้งเดิม เช่น Texture Features, Histogram Features หรือ Deep Feature Embedding แต่เลือกใช้แนวทางการวิเคราะห์เชิงเรขาคณิต (Geometric Analysis) และข้อมูลเชิงพื้นที่ของรอยผุภายในพื้นผิวฟันเพื่อใช้ในการจำแนกพื้นผิวฟันผุออกเป็น 3 ประเภท ได้แก่ Occlusal, Mesial และ Distal

แนวคิดหลักของระบบคือ การใช้ตำแหน่งของรอยผุภายใน Tooth Mask เป็นตัวกำหนดว่ารอยผุนั้นอยู่บนพื้นผิวใดของฟัน ดังนั้น ระบบจำเป็นต้องสร้าง “ระบบอ้างอิงเชิงพื้นที่ของฟัน” (Tooth Spatial Reference System) เช่น ตัวอย่างในภาพที่ 14 เพื่อให้ฟันแต่ละซี่สามารถถูกวิเคราะห์ในทิศทางเดียวกันก่อนเข้าสู่กระบวนการแบ่งโซนพื้นผิว



ภาพที่ 14 Overview ของ Spatial Reference System ที่แสดง Tooth Mask, Centroid และ PCA Axis

เนื่องจากภาพ Panoramic Radiograph มีความหลากหลายสูง ทั้งในด้านมุมเอียง รูปร่างฟัน และคุณภาพของการ Segmentation หากไม่มีการจัดแนวฟันที่สอดคล้องกัน ตำแหน่งของรอยผุจะถูกตีความแตกต่างกันในแต่ละภาพ ส่งผลให้การแบ่งโซนฟันเกิดความคลาดเคลื่อน และลดความแม่นยำของระบบโดยรวม

ดังนั้น ระบบจึงใช้ข้อมูลจาก Tooth Segmentation Mask (ภาพที่ 4) เพื่อคำนวณคุณลักษณะเชิงเรขาคณิตของฟัน เช่น จุดศูนย์กลางของฟัน (Centroid) แนวแกนหลักของฟัน (Principal Axis) ความกว้างและความสูงของ Bounding Box รวมถึงทิศทางการกระจายตัวของพิกเซลภายในฟัน เพื่อนำมาใช้ในการจัดแนวฟันซึ่งจะพัฒนาต่อเป็นวิธีการจำแนกด้านที่มีรอยผุโดยมีวิธีการต่อไปนี้

3.3.1 PCA (Principal Component Analysis)

การหาแกนหลักด้วย PCA (Principal Component Analysis) เป็นการประยุกต์ใช้เทคนิค PCA เพื่อคำนวณหา "แกนยาวของฟัน" (Long Axis) จากพิกเซลใน Tooth Mask โดยอาศัยค่า Eigenvector แรกในการระบุทิศทางหลักของโครงสร้างฟัน กระบวนการนี้ช่วยให้ระบบสามารถคำนวณมุมเอียงของฟันแต่ละซี่ได้อย่างแม่นยำ เพื่อนำไปสู่ขั้นตอนการปรับทิศทางให้ตั้งตรง (Orientation Normalization)

3.3.1.1 ตรรกะการหมุนภาพ (Rotation Logic) ในการปรับแนวแกน ระบบจะใช้จุดศูนย์กลางมวล (Centroid) ของฟันเป็นจุดหมุนหลักโดยทำการหมุนทั้งโครงสร้างฟัน (Tooth Mask) และรอยผุ (Caries Mask) ไปพร้อมกันด้วยมุมที่คำนวณได้จาก PCA เพื่อให้มั่นใจว่าตำแหน่งความสัมพันธ์เชิงพื้นที่ระหว่างรอยผุและตัวฟันยังคงความถูกต้องภายหลังจากที่ฟันถูกปรับให้อยู่ในแนวแกนตั้งตรงแล้ว


3.3.1.2 การสร้างขอบเขตและการแบ่งโซนพื้นที่ (Bounding Box and Spatial Zoning) เมื่อฟันอยู่ในแนวแกนที่กำหนด ระบบจะสร้างกล่องขอบเขต (Bounding Box) ดังตัวอย่างในภาพที่ 14 เพื่อครอบคลุมพื้นที่ของฟันเพื่อใช้เป็นเกณฑ์ในการแบ่งโซนเชิงสัดส่วน ดังนี้

3.3.1.2.1 Occlusal Zone: กำหนดพื้นที่ส่วนบนหรือส่วนล่างของกล่อง (ขึ้นอยู่กับตำแหน่งขากรรไกร) ในสัดส่วน 20% เพื่อระบุเป็นพื้นที่ด้านบดเคี้ยว

3.3.1.2.2 Mesial Zone: กำหนดพื้นที่ 20% บริเวณขอบซ้ายหรือขวาสุดของกล่อง (ขึ้นอยู่กับตำแหน่งขากรรไกร) เพื่อระบุเป็นพื้นที่ด้านประชิดด้านหน้าฟัน

3.3.1.2.3 Distal Zones: กำหนดพื้นที่ 20% บริเวณขอบซ้ายหรือขวาสุดของกล่อง (ขึ้นอยู่กับตำแหน่งขากรรไกร) เพื่อระบุเป็นพื้นที่ด้านประชิดด้านหลังฟัน

3.3.1.3 การประยุกต์ใช้ตรรกะทางกายวิภาค (FDI Jaw Logic) เพื่อให้การจำแนกสอดคล้องกับหลักทันตกรรม ระบบได้นำเลขระบุซี่ฟันตามมาตรฐาน FDI ในภาพที่ 15 มาใช้ในการจำแนกตำแหน่งขากรรไกรบนและล่าง ตรรกะนี้ช่วยให้ระบบสามารถปรับเปลี่ยนกฎการแบ่งพื้นที่ (Zoning Rules) ให้ถูกต้องตามลักษณะกายวิภาคที่แตกต่างกันของฟันแต่ละตำแหน่ง ซึ่งช่วยเพิ่มความน่าเชื่อถือในการทำนายฟันผุฟันผุในขั้นตอนสุดท้าย



ภาพที่ 15 FDI Jaw Logic เพื่อใช้ในการจำแนกตำแหน่งขากรรไกรบนและล่าง


ภาพจาก [https://www.researchgate.net/figure/The-illustration-of-FDI-World-Dental-Federation-notation-The-system-designates-each_fig1_359614391]

3.3.2 Neighbor-Aware Orientation

แนวทางนี้เป็นการประมาณค่าแนวแกนของฟัน (Axis Estimation) โดยอาศัยความสัมพันธ์ของการเรียงตัวของฟันซึ่งข้างเคียงตามแนวโค้งของขากรรไกร (Dental Arch Alignment)

3.3.2.1 กระบวนการทำงาน (Procedure) ระบบจะทำการคำนวณหาจุดศูนย์กลางมวล (Centroids) ของฟันซึ่งข้างเคียงดังตัวอย่างในภาพที่ 16 เพื่อนำมาประเมินทิศทางและสร้างเส้นโค้งจำลองของ

ขากระดูก (Arch Direction) จากนั้นจึงกำหนดแกนตั้งอ้างอิง (Vertical Axis) ของฟันซึ่งเป้าหมายให้ทำมุมตั้งฉากกับเส้นโค้งขากระดูกบริเวณดังกล่าว



ภาพที่ 16 Neighbor-Aware Orientation แสดงผลลัพธ์ของการคำนวณ Centroid (จุดสีแดง) โดยใช้แนวฟัน

3.3.2.2 ข้อจำกัด (Limitations) จากการทดลองพบว่า วิธีการนี้มีข้อจำกัดสำคัญในขั้นตอนการดึงข้อมูล (Data Extraction) เนื่องจากความไม่สมบูรณ์ของข้อมูล Tooth Mask ในชุดข้อมูล JSON ส่งผลให้ข้อมูลฟันข้างเคียงบางซี่ขาดหายไป นอกจากนี้ ความแปรปรวนทางกายวิภาคของบุคคลยังทำให้การเรียงตัวของแนวฟัน (Row Alignment) ขาดความเสถียร ซึ่งส่งผลกระทบโดยตรงต่อความแม่นยำในการคำนวณแกนตั้งฉาก คณะผู้จัดทำจึงพบว่าวิธีการนี้อาจยังไม่เหมาะสมต่อการนำไปใช้งานจริงในชุดข้อมูลนี้

3.3.3 Skeleton / Medial Axis


แนวทางนี้ประยุกต์ใช้การวิเคราะห์โครงสร้างของฟัน เพื่อสกัดหาแนวแกนทางกายวิภาค) ที่แท้จริง แทนการพิจารณาจากขอบเขตภายนอกเพียงอย่างเดียว โดยมีกระบวนการประมวลผลเชิงพื้นที่ (Spatial Processing) ดังขั้นตอนต่อไปนี้

3.3.3.1 การสร้างโครงร่าง (Skeletonization): ระบบจะทำการแปลงบริเวณของ Tooth Mask ให้หดเล็กลงจนเหลือเพียงเส้นโครงร่างหรือแกนกลาง (Medial Axis)

3.3.3.2 การระบุจุดปลาย (Endpoint Detection): อัลกอริทึมจะทำการค้นหาและระบุพิกัดของจุดปลายสุด (Endpoints) ของเส้นแกนกลางที่ได้จากขั้นตอนแรก

3.3.3.3 การจำแนกส่วนรากและตัวฟัน (Root-to-Crown Identification): ทำการวิเคราะห์ความหนาแน่นของพิกเซลเดิมบริเวณรอบๆ จุดปลาย โดยอาศัยตรรกะที่ว่าส่วนรากฟัน (Root) จะมีลักษณะเรียวเล็กกว่าส่วนตัวฟัน (Crown) เพื่อกำหนดทิศทางบน-ล่าง

3.3.3.4 การกำหนดแนวแกน (Axis Definition): เมื่อทราบตำแหน่งรากและตัวฟัน ระบบจะลากเส้นเวกเตอร์อ้างอิงจากรากไปยังตัวฟัน เช่น ตัวอย่างในภาพที่ 17 เพื่อใช้เป็นแกนตั้ง (Vertical Axis) สำหรับการปรับจัดแนว (Alignment)



ภาพที่ 17 Skeleton / Medial Axis ที่ Tooth mask แปลงเป็น Skeleton แสดงแกนที่ลากจากรากไปตัวฟัน

(หมายเหตุ: สีแดง: ตัวฟัน (Crown), สีเขียว: ด้านประชิดหน้า (Mesial), สีชมพู: ด้านประชิดหลัง (Distal))

3.3.3.5 จุดเด่น (Strengths) วิธีการนี้มีพื้นฐานที่สอดคล้องกับลักษณะทางกายวิภาคศาสตร์ของฟันอย่างเป็นธรรมชาติ (Anatomically intuitive) ทำให้แนวแกนที่ได้สะท้อนโครงสร้างที่แท้จริงของฟัน

3.3.3.6 ข้อจำกัด (Limitations) จากการทดลองพบว่า อัลกอริทึมนี้มีความอ่อนไหวสูงมาก (Highly sensitive) ต่อสัญญาณรบกวน (Noise) ที่เกิดจากความผิดพลาดของกระบวนการ Segmentation เบื้องต้น หากข้อมูล Tooth Mask มีรอยแหว่ง ขอบไม่เรียบ หรือข้อมูลไม่สมบูรณ์ (Incomplete masks) จะส่งผลให้เส้นแกนกลางบิดเบี้ยวและเกิดจุดปลายหลอก (False endpoints) จำนวนมาก ทำให้การคำนวณแนวแกนขาดความเสถียร (Unstable) และไม่สามารถนำมาใช้เป็นวิธีหลักในระบบได้

หลังจากฟันแต่ละซี่ถูกจัดแนวแล้ว ระบบจะทำการแบ่งพื้นที่ของฟันออกเป็นหลายโซน เพื่อใช้วิเคราะห์ตำแหน่งของรอยผุภายใน Tooth Mask โดยแนวคิดของการแบ่งโซนพื้นผิวฟัน (Surface Zoning) คือ การกำหนดขอบเขตเชิงพื้นที่ของพื้นผิวแต่ละประเภท เพื่อให้ระบบสามารถระบุได้ว่ารอยผุอยู่บริเวณด้านบดเคี้ยว (Occlusal) หรือด้านข้างของฟัน (Mesial / Distal) การคัดเลือกแนวทางที่เหมาะสมที่สุดสำหรับระบบในหัวข้อถัดไป

3.3.4 Surface Classification

เมื่อได้แนวแกนของฟันแล้ว ระบบจะทำการวิเคราะห์ตำแหน่งของรอยผุภายในฟัน โดยใช้ ROI Mask ของรอยผุร่วมกับ Tooth Mask เพื่อกำหนดตำแหน่งเชิงพื้นที่ของรอยฟันผุ จากนั้นระบบจะทำการแบ่งพื้นที่ของฟันออกเป็นโซนต่าง ๆ ตามกฎเชิงเรขาคณิต เช่น X-Thirds Dominant (ภาพที่ 18) หรือ Diagonal-from-Centroid (ภาพที่ 19) และใช้ตำแหน่งของรอยผุในการกำหนดตำแหน่งพื้นผิวฟันผุ (Surface Prediction)

กระบวนการทั้งหมดนี้ถือเป็นแกนหลักของงานวิจัย เนื่องจากหัวใจสำคัญของโครงการคือการศึกษา “การจำแนกด้านที่มีรอยผุ” ที่เหมาะสมที่สุดสำหรับการจำแนกตำแหน่งรอยผุจากข้อมูลภาพทางทันตกรรม เพื่อศึกษาประสิทธิภาพของแนวทางต่าง ๆ จึงพัฒนาและเปรียบเทียบหลาย Method ตั้งแต่การปรับแนวแกนฟัน ไปจนถึงวิธีแบ่งโซนพื้นผิวในรูปแบบต่าง ๆ ซึ่งมีรายละเอียดดังต่อไปนี้

3.3.4.1 Method 1: Standard PCA (Baseline)

วิธีเริ่มต้นของระบบใช้ Principal Component Analysis (PCA) เพื่อหาแนวแกนหลักของฟันจาก Pixel-level Tooth Mask โดยเลือกแกนที่มีค่าความแปรปรวนสูงสุดเป็นแนวอ้างอิงสำหรับการหมุนฟันให้อยู่ในแนวเดียวกันก่อนเข้าสู่กระบวนการแบ่งโซนพื้นผิว

แนวคิดของวิธีนี้คือ หากสามารถปรับแนวของฟันให้สอดคล้องกันได้ การแบ่งพื้นที่ Mesial, Occlusal และ Distal จะมีความแม่นยำมากขึ้น อย่างไรก็ตาม ในการทดลองจริงพบว่า PCA มีข้อจำกัดสำคัญในฟันกรามที่มีลักษณะสมมาตรหรือมี Bounding Box ใกล้เคียงรูปสี่เหลี่ยม ส่งผลให้เกิดปัญหา Axis Flipping หรือการหมุนแกนผิดพลาดทางปัญหาดังกล่าวทำให้ตำแหน่งของพื้นผิวฟันถูกสลับด้าน และส่งผลโดยตรงต่อความแม่นยำของการจำแนก Surface Classification ผลการทดลองของวิธีนี้ให้ค่า Macro F1-Score เท่ากับ 0.30 ซึ่งถือเป็น Baseline สำหรับการพัฒนาวิธีการในลำดับถัดไป

3.3.4.2 Method 2: Conditional Ratio

เพื่อแก้ปัญหาการหมุนผิดแนวของ PCA วิธีนี้จึงเพิ่มเงื่อนไขตรวจสอบอัตราส่วนความกว้างต่อความสูง (Width-to-Height Ratio) ของ Bounding Box ก่อนทำการกำหนดแนวแกน

หาก Bounding Box มีลักษณะสูงหรือกว้างผิดปกติ ระบบจะปรับทิศทางของแกน PCA ให้สอดคล้องกับลักษณะของฟันมากขึ้น เพื่อลดโอกาสเกิดการหมุนผิด 90 องศา

ผลการทดลองพบว่าวิธีนี้สามารถลดปัญหา Axis Flipping ได้บางส่วน โดยเฉพาะในฟันกรามที่มีรูปทรงใกล้เคียงสี่เหลี่ยม อย่างไรก็ตาม วิธีนี้ยังคงอาศัยลักษณะของ Bounding Box เป็นหลัก ทำให้ยังมีความไวต่อความผิดพลาดของ Segmentation วิธีนี้ให้ค่า Macro F1-Score เพิ่มขึ้นเป็น 0.40

3.3.4.3 Method 3: Maximum Projected Span

วิธีนี้พัฒนาต่อจาก PCA โดยเปลี่ยนจากการใช้แกนที่มี Variance สูงสุด มาเป็นการหาแนวแกนที่มีระยะการกระจายตัวของพิกเซลยาวที่สุดในเชิงกายภาพ (Maximum Projected Span)

แนวทางนี้ช่วยลดผลกระทบจากความหนาแน่นของจุดพิกเซลภายใน Mask และทำให้ระบบเลือกแนวแกนตามลักษณะรูปร่างจริงของฟันมากขึ้น ผลการทดลองพบว่าวิธีนี้มีความเสถียรมากกว่า Conditional Ratio และสามารถลดความผิดพลาดจากโครงสร้างพิกเซลที่ไม่สมดุลได้ในบางกรณี Macro F1-Score ของวิธีนี้อยู่ที่ 0.40

3.3.4.4 Method 4: Split-Centroid Anatomy

วิธีนี้ถูกพัฒนาขึ้นจากแนวคิดทางกายวิภาคของฟัน โดยแบ่ง Tooth Mask ออกเป็นส่วนบนและล่าง จากนั้นคำนวณจุดศูนย์กลาง (Centroid) แต่ละส่วน และสร้างเวกเตอร์จากบริเวณรากฟันไปยังฟันเพื่อใช้เป็นแนวอ้างอิง

แนวทางดังกล่าวช่วยให้ระบบสามารถประมาณทิศทางของฟันได้สอดคล้องกับลักษณะทางกายวิภาคจริงมากขึ้น และลดปัญหาการหมุนผิดแนวที่พบใน PCA ได้อย่างมีประสิทธิภาพ นอกจากนี้ วิธีนี้ยังมีความทนทานต่อ Noise และความผิดพลาดของ Tooth Segmentation มากกว่าวิธีที่ผ่านมา เนื่องจากอาศัยโครงสร้างภาพโดยรวมมากกว่าการกระจายตัวของพิกเซลเพียงอย่างเดียว

ผลการทดลองพบว่าวิธีนี้ให้ค่า Macro F1-Score อยู่ที่ 0.41

3.3.4.5 Method 5: Furthest Point Alignment (Conceptual Method)

วิธีนี้ใช้หลักการหาจุดที่อยู่ไกลที่สุดจากจุดศูนย์กลางของฟัน เพื่อใช้เป็นแนวอ้างอิงสำหรับกำหนดทิศทางของฟัน แม้แนวคิดดังกล่าวจะสามารถทำงานได้ในกรณีที่ Tooth Mask มีความสมบูรณ์ แต่ในการทดลองจริงพบว่าวิธีนี้มีความไวต่อข้อผิดพลาดของ Segmentation สูงมาก โดยเฉพาะกรณีที่บริเวณรากฟันถูกตัดขาดหรือ Segment ไม่ครบ ปัญหาดังกล่าวทำให้ตำแหน่งอยู่ไกลที่สุดจากจุดศูนย์กลางของฟันเปลี่ยนแปลงได้ง่าย ส่งผลให้แนวแกนไม่เสถียรและไม่เหมาะสมสำหรับใช้งานจริง ดังนั้น วิธีนี้จึงไม่ได้ถูกเลือกใช้งานต่อในขั้นตอนสุดท้ายของระบบ

3.3.4.6 Method 6: Absolute Vertical Prior

วิธีนี้กำหนดให้ฟันทุกซี่ตั้งตรงตามแนวแกนแนวตั้งของภาพเอกซเรย์ โดยไม่อาศัยข้อมูลเชิงรูปร่างของฟันหรือการคำนวณ PCA แนวทางดังกล่าวช่วยลดความซับซ้อนของระบบ และลดปัญหาการคำนวณแกนผิดพลาดในบางกรณี อย่างไรก็ตาม วิธีนี้มีข้อจำกัดสำคัญคือมีความไวต่อการเอียงของภาพพาโนรามาโดยรวม

เมื่อภาพ X-ray ถูกถ่ายในมุมที่เอียง แนวตั้งของภาพจะไม่สอดคล้องกับแนวจริงของฟัน ส่งผลให้การแบ่งโซนฟันเกิดความคลาดเคลื่อน ผลการทดลองของวิธีนี้ให้ค่า Macro F1-Score เท่ากับ 0.40

3.3.4.7 Method 7: Multi-Class Segmentation (Conceptual Method)

วิธีนี้เป็นแนวคิดเชิงทฤษฎีที่เสนอให้แยกส่วน Crown และ Root ตั้งแต่ขั้นตอนการสอน AI เพื่อให้ระบบสามารถวิเคราะห์เฉพาะบริเวณตัวฟัน (Crown) ได้โดยตรง

แนวทางดังกล่าวจะช่วยลดปัญหาที่เกิดจาก Bounding Box ที่รวมรากฟันเข้ามาด้วย ซึ่งเป็นสาเหตุสำคัญของความผิดพลาดในการแบ่งโซนแบบเรขาคณิต โดยเฉพาะในวิธี Diagonal-from-Centroid หากสามารถสร้างโมเดลลักษณะนี้ได้ จะช่วยให้การแบ่งพื้นที่ Occlusal, Mesial และ Distal มีความแม่นยำมากขึ้น และลด Trade-off ระหว่างคลาสได้อย่างมีนัยสำคัญ

อย่างไรก็ตาม วิธีนี้จำเป็นต้องมีการสร้าง Annotation ใหม่ในระดับ Pixel-Coordinate สำหรับ Crown และ Root แยกจากกันทั้งหมด ซึ่งอยู่นอกขอบเขตของโครงการนี้ จึงยังไม่ได้ถูกนำมาใช้งานจริง

3.4 การปรับปรุงกระบวนการจำแนกด้านที่มีรอยผุ

หลังจากการทดลองจำแนกพื้นผิวฟันผุในระยะแรก โดยเฉพาะคลาส Occlusal ซึ่งเกิดความคลาดเคลื่อนจากการคำนวณแนวแกนฟันด้วย PCA และการแบ่งโซนพื้นผิวฟัน พบว่าผลลัพธ์ยังไม่เป็นที่น่าพึงพอใจ (ตารางที่ 3) จึงทำให้จำเป็นต้องปรับปรุง PCA และกระบวนการจำแนกด้านที่มีรอยผุด้วยวิธีการดังต่อไปนี้

3.4.1 Improved PCA

จากผลการทดลองในระยะแรก พบว่าการคำนวณแนวแกนฟันด้วย Principal Component Analysis (PCA) แบบเดิมมีความคลาดเคลื่อนในฟันบางซี่ (ภาพที่ 7) โดยเฉพาะกรณีที่ Tooth Mask มีลักษณะไม่สมมาตร หรือมีส่วนของรากฟันรวมอยู่ภายใน Segmentation ส่งผลให้ทิศทางของแกน PCA เอียงผิดจากแนวแกนจริงของฟัน และกระทบต่อกระบวนการแบ่งโซนพื้นผิวฟันในขั้นตอนถัดไป

ดังนั้น จึงทำการปรับปรุงกระบวนการคำนวณ PCA โดยลดผลกระทบจากรูปร่างของรากฟัน และปรับการคำนวณแนวแกนให้สอดคล้องกับโครงสร้างของตัวฟันมากขึ้น เพื่อช่วยให้การวิเคราะห์ตำแหน่งรอยผุและการแบ่งโซนพื้นผิวฟันมีความแม่นยำและเสถียรมากขึ้น

3.4.2 Improved Surface Classification

จากผลการทดลองที่ได้ จึงทำให้ต้องมีการปรับปรุงกระบวนการแบ่งโซนพื้นผิวฟัน และทดลองวิธีการวิเคราะห์เชิงเรขาคณิตหลายรูปแบบ เช่น X-Thirds Dominant Zone และ Diagonal-from-Centroid เพื่อเปรียบเทียบประสิทธิภาพและเลือกแนวทางที่เหมาะสมที่สุดสำหรับการจำแนกพื้นผิวฟันผุ


3.4.2.1 Method 8: X-Thirds Dominant Zone

หลังจากทดลองหลายวิธีในการหาแนวแกนและแบ่งโซนพื้นผิว คณะผู้จัดทำพบว่าปัญหาหลักของระบบไม่ได้เกิดจากการหมุนแกนเพียงอย่างเดียว แต่เกิดจาก “ลักษณะการแบ่งพื้นที่ภายในฟัน” ที่ไม่สอดคล้องกับการกระจายตัวจริงของรอยผุ

วิธี X-Thirds Dominant Zone (ภาพที่ 18) จึงถูกพัฒนาขึ้นโดยแบ่งพื้นที่ฟันตามแนวนอนออกเป็น 3 ส่วน ได้แก่ Mesial (40%), Occlusal (20%) และ Distal (40%) จากนั้นระบบจะคำนวณว่าพื้นที่ของรอยผุอยู่ในโซนใดมากที่สุด และใช้โซนนั้นเป็นผลลัพธ์ของ Surface

Classification แนวทางนี้ช่วยรักษาพื้นที่ของ Mesial และ Distal ซึ่งเป็นคลาสส่วนใหญ่ของข้อมูล ทำให้สามารถลดความผิดพลาดโดยรวมของระบบได้อย่างมีประสิทธิภาพ


ผลการทดลองพบว่าวิธีนี้ให้ Accuracy สูงสุดที่ 70.54% และได้ค่า Macro F1-Score เท่ากับ 0.4714



ภาพที่ 18 ภาพ X-Thirds Dominant Zone เพื่อ เปรียบเทียบผลการแบ่งโซนทั้ง 2 วิธี X-Thirds vs Diagonal (หมายเหตุ: การแบ่งด้านฟันผุ สีฟ้า: ด้านประชิดหน้า (Mesial), สีเขียว: ด้านประชิดหลัง (Distal), สีชมพูอ่อน: ด้านบดเคี้ยว (Occlusal) / ความถูกต้องในการแบ่งด้านฟันผุ สีเขียว: ถูกต้อง, สีแดง: ผิด)

3.4.2.2 Method 9: Diagonal-from-Centroid

วิธีนี้ถูกพัฒนาขึ้นเพื่อแก้ปัญหารอยผุบริเวณมุมโค้งของฟัน ซึ่งมักถูกจำแนกผิดในระบบแบบ X-Thirds แนวทางนี้ใช้เส้นทแยงมุมจากจุด Centroid เพื่อแบ่งพื้นที่ฟันออกเป็น 4 ส่วน ลักษณะสามเหลี่ยม (ภาพที่ 19) ทำให้พื้นที่บริเวณ Occlusal มีความยืดหยุ่นมากขึ้นและสามารถครอบคลุมรอยผุบริเวณมุมโค้งได้ดีขึ้น



ภาพที่ 19 ภาพ Diagonal-from-Centroid เส้นทแยงมุมผ่าน centroid และ พื้นที่สามเหลี่ยม
เพื่อ เปรียบเทียบผลการแบ่งโซนทั้ง 2 วิธี X-Thirds vs Diagonal

(หมายเหตุ: ความถูกต้องในการแบ่งด้านฟันผุ สีเขียว: ถูกต้อง, สีแดง: ผิด)

ผลการทดลองพบว่า Recall ของคลาส Occlusal เพิ่มขึ้นอย่างชัดเจนจาก 0.20 เป็น 0.69 อย่างไรก็ตาม วิธีนี้กลับทำให้พื้นที่ด้าน Mesial และ Distal ถูกบีบแคบลง เนื่องจาก Bounding Box ของฟันมีลักษณะสูงจากการรวมรากฟัน ส่งผลให้รอยผุจำนวนมากถูกจำแนกผิดจาก Distal ไปเป็น Occlusal และทำให้ Accuracy โดยรวมลดลง ผลการทดลองของวิธีนี้ให้ Accuracy เท่ากับ 60.28% และ Macro F1-Score เท่ากับ 0.4601

บทที่ 4

ผลการทดลอง

ด้วยการพัฒนา Hybrid Framework และการทดลองวิธีการต่าง ๆ ครอบคลุมแล้ว จึงดำเนินการประเมินผลระบบอย่างเป็นระบบ โดยใช้ตัวชี้วัดหลายรูปแบบร่วมกับการทดสอบทางสถิติ เพื่อวิเคราะห์ประสิทธิภาพ ความเสถียร และข้อจำกัดของแต่ละแนวทาง

4.1 ผลที่ได้จาก Dataset

ในกระบวนการทดสอบและประเมินผล ได้ปรับปรุงเกณฑ์การคัดเลือกข้อมูล (Selection Criteria) ให้มีความครอบคลุมมากขึ้น โดยในระยะแรกของการทดสอบระบบได้จำกัดการประเมินเฉพาะรอยโรคจำนวน 1,743 รายการ ที่สามารถผ่านกระบวนการปรับแนวแกนด้วยอัลกอริทึม PCA แบบเดิม ได้เท่านั้น

อย่างไรก็ตาม เมื่อได้พัฒนา **Method 8: X-Thirds Dominant Zone** (ภาพที่ 18) ร่วมกับวิธีการปรับแนวแกนที่เสถียรขึ้น ระบบสามารถรองรับและประมวลผลรอยโรคที่มีความซับซ้อนเชิงรูปร่างได้ครอบคลุมมากขึ้น จึงตัดสินใจขยายขอบเขตการประเมินผลในขั้นสุดท้าย (Final Evaluation) ให้ครอบคลุมรอยโรคที่ผ่านการตรวจสอบความสมบูรณ์แล้ว (Valid Cases) ทั้งหมด **1,979 รายการ** เพื่อทดสอบขีดจำกัดและความเสถียร (Consistency) ของระบบในสถานะที่มีความแปรปรวนของข้อมูลสูง

4.2 ผลจากการระบุซี่ฟันที่มีรอยผุ

หลังจากดำเนินกระบวนการ Caries-to-Tooth Mapping โดยใช้ ROI Mask ของรอยผุร่วมกับ Tooth Segmentation เพื่อคำนวณพื้นที่ซ้อนทับของพิกเซล (Intersection) ระบบสามารถระบุ Tooth ID ของฟันที่มีรอยผุได้ และสามารถเชื่อมโยงตำแหน่งของรอยผุเข้ากับฟันแต่ละซี่ภายในภาพ Panoramic Radiograph ได้สำเร็จ

ผลลัพธ์จากขั้นตอนนี้ทำให้ระบบสามารถสร้างข้อมูลในระดับฟันแต่ละซี่ ซึ่งประกอบด้วย Tooth ID, Pixel ของรอยผุ และตำแหน่งเชิงพื้นที่ของรอยผุภายในฟัน เพื่อนำไปใช้ต่อในกระบวนการวิเคราะห์เชิงเรขาคณิต และการจำแนกด้านที่มีรอยผุ (Surface Classification)

อย่างไรก็ตาม จากการตรวจสอบผลลัพธ์และภาพ Visualization พบว่าบางกรณียังเกิดความคลาดเคลื่อนจากปัญหา Tooth Overlapping, Incomplete Segmentation และ ROI ของรอยฟันที่อยู่ใกล้ขอบฟัน ซึ่งอาจส่งผลกระทบต่อความแม่นยำของการระบุ Tooth ID

4.3 ผลจากการจำแนกด้านที่มีรอยฟัน

ในหัวข้อนี้ เสนอผลการประเมินประสิทธิภาพของแบบจำลองเชิงเรขาคณิตทั้งหมดที่ถูกพัฒนาขึ้นเพื่อใช้ในการจำแนกพื้นผิวฟันผุ (Surface Classification) โดยตรง เพื่อให้เห็นภาพรวมของพัฒนาการและการออกแบบอัลกอริทึม (Iterative Algorithm Design) จึงได้จัดกลุ่มวิธีการทดลองทั้งหมดตาม "กลไกหลักที่เป็นจุดเปลี่ยนของแต่ละโมเดล" ได้แก่:

4.3.1 Method 1: Standard PCA (Baseline Model)

4.3.1.1 ผลการจำแนก Macro F1-score: 0.30

4.3.1.2 การวิเคราะห์ โมเดลพื้นฐานนี้ใช้การกระจายตัวของพิกเซลในการหาแกนหลัก แต่พบความล้มเหลวอย่างหนักในฟันกรามที่มีรูปทรงสมมาตร เนื่องจากเกิดปัญหา **Axis Flipping** (การกลับทิศทางของแกน 90 องศา) ส่งผลให้ระบบทำนายคลาสพื้นผิวสลับด้านกันทั้งหมด

=== perform_pca_0 ===


Confusion Matrix:

```
[[326  7  4]
 [435 68 59]
 [473 171 162]]
```

Report:

	precision	recall	f1-score	support
Occlusal	0.26	0.94	0.41	347
Mesial	0.28	0.12	0.17	577
Distal	0.72	0.20	0.31	819
micro avg	0.33	0.32	0.32	1743
macro avg	0.42	0.42	0.30	1743
weighted avg	0.48	0.32	0.28	1743

ภาพที่ 20 Classification Report ของ Method 1: Standard PCA (Baseline Model)



ภาพที่ 21 Evaluation ของ Method 1: Standard PCA (Baseline Model)

4.3.2 Method 2: Conditional Ratio

4.3.2.1 ผลการจำแนก Macro F1-score: 0.40

4.3.2.2 การวิเคราะห์ การเพิ่มกฎเกณฑ์ (Heuristics) เช่น การตรวจสอบสัดส่วน Bounding Box หรือการใช้ระยะสแปนทางกายภาพ ช่วยแก้ปัญหาแกนกลับทิศทางได้ในหลายกรณี ทำให้คะแนนรวมสูงขึ้น แต่โมเดลยังขาดความเสถียร หากภาพผลลัพธ์ของ Tooth Mask มีขอบเขตที่ผิดเพี้ยน

=== perform_pca_1 ===


Confusion Matrix:

```
[[269  54  14]
 [340 210  12]
 [440 153 213]]
```

Report:

	precision	recall	f1-score	support
Occlusal	0.26	0.78	0.39	347
Mesial	0.50	0.36	0.42	577
Distal	0.89	0.26	0.40	819
micro avg	0.41	0.40	0.40	1743
macro avg	0.55	0.47	0.40	1743
weighted avg	0.64	0.40	0.41	1743

ภาพที่ 22 Classification Report ของ Method 2: Conditional Ratio Evaluation



ภาพที่ 23 Evaluation ของ Method 2: Conditional Ratio Evaluation

4.3.3 Method 3: Maximum Projected Span

4.3.3.1 ผลการจำแนก Macro F1-score: 0.40

4.3.3.2 การวิเคราะห์ การเพิ่มกฎเกณฑ์ (Heuristics) เช่น การตรวจสอบสัดส่วน Bounding Box หรือการใช้ระยะสแปนทางกายภาพ ช่วยแก้ปัญหาแกนกลับทิศทางได้ในหลายกรณี ทำให้คะแนนรวมสูงขึ้น แต่ไม่ลดยังขาดความเสถียร หากภาพผลลัพธ์ของ Tooth Mask มีขอบเขตที่ผิดเพี้ยน

```
=== perform_pca_2 ===
```

Confusion Matrix:

```
[[269  54  14]
```


```
 [338 211  13]
```

```
 [440 153 213]]
```

Report:

	precision	recall	f1-score	support
Occlusal	0.26	0.78	0.39	347
Mesial	0.50	0.37	0.42	577
Distal	0.89	0.26	0.40	819
micro avg	0.41	0.40	0.40	1743
macro avg	0.55	0.47	0.40	1743
weighted avg	0.64	0.40	0.41	1743

ภาพที่ 24 Classification Report ของ Method 3: Maximum Projected Span Evaluation



ภาพที่ 25 Evaluation ของ Method 3: Maximum Projected Span Evaluation

4.3.4 Method 4: Split-Centroid Anatomy

4.3.4.1 ผลการจำแนก Macro F1-score: 0.41

4.3.4.2 การวิเคราะห์ การแบ่ง Tooth Mask เป็นส่วนบนและล่างเพื่อหาเวกเตอร์แกนกลางตามหลักกายวิภาค พิสูจน์แล้วว่าเป็นโมเดลที่มีความทนทานต่อสัญญาณรบกวน (Noise) มากที่สุดในกลุ่มนี้ ช่วยลดความผิดพลาดจากการทำนายสลับด้านได้อย่างมีประสิทธิภาพ

=== perform_pca_3 ===


Confusion Matrix:

```
[[273  51  13]
 [339 210  13]
 [440 153 213]]
```

Report:

	precision	recall	f1-score	support
Occlusal	0.26	0.79	0.39	347
Mesial	0.51	0.36	0.42	577
Distal	0.89	0.26	0.40	819
micro avg	0.41	0.40	0.40	1743
macro avg	0.55	0.47	0.41	1743
weighted avg	0.64	0.40	0.41	1743

ภาพที่ 26 Classification Report ของ Method 4: Split-Centroid Anatomy Evaluation



ภาพที่ 27 Evaluation ของ Method 4: Split-Centroid Anatomy Evaluation

4.3.5 Method 6: Absolute Vertical Prior

4.3.5.1 ผลการจำแนก Macro F1-score: 0.40

4.3.5.2 การวิเคราะห์ โมเดลนี้ตัดการคำนวณแกนทั้งและบังคับให้ฟันตั้งตรงตามแนวแกนภาพ แม้จะลดความซับซ้อนได้ แต่กลับมีความอ่อนไหวสูง (Highly sensitive) ต่อความเอียงของภาพ พาโนรามาต้นฉบับ ทำให้การจำแนกคลาดเคลื่อนทันทีหากภาพเอียง

=== perform_pca_5 ===


Confusion Matrix:

```
[[270  53  14]
 [348 211   3]
 [452 150 204]]
```

Report:

	precision	recall	f1-score	support
Occlusal	0.25	0.78	0.38	347
Mesial	0.51	0.37	0.43	577
Distal	0.92	0.25	0.39	819
micro avg	0.40	0.39	0.40	1743
macro avg	0.56	0.46	0.40	1743
weighted avg	0.65	0.39	0.40	1743

ภาพที่ 28 Classification Report ของ Method 6: Absolute Vertical Prior



ภาพที่ 29 Evaluation ของ Method 6: Absolute Vertical Prior

4.4 ผลจากการปรับปรุงกระบวนการจำแนกด้านที่มีรอยผุ

หลังจากพบข้อจำกัดว่าการแก้ปัญหาที่แนวแกนเพียงอย่างเดียวไม่สามารถเพิ่มความแม่นยำได้มากนัก จึงพัฒนาโมเดลกลุ่มใหม่ที่มุ่งเน้น "การปรับเปลี่ยนตรรกะการแบ่งโซนพื้นที่ (Spatial Partitioning Logic)" ให้สอดคล้องกับการกระจายตัวของรอยโรคในชุดข้อมูลด้วยวิธีการดังนี้

4.4.1 Method 8: X-Thirds Dominant Zone (Final Proposed Model)

4.4.1.1 ผลการจำแนก: Accuracy: 70.54% | Macro F1-score: 0.4714

4.4.1.2 การวิเคราะห์: โมเดลนี้แบ่งพื้นที่ตามแนวนอนด้วยสัดส่วน 40%–20%–40% เพื่อรักษาสัดส่วนพื้นที่ของด้านประชิด (Mesial/Distal) ซึ่งเป็นประชากรส่วนใหญ่ (Majority Class) ของชุดข้อมูลเอาไว้ การออกแบบโมเดลในลักษณะนี้ทำหน้าที่เสมือนเกราะป้องกัน (Buffer) ผลกระทบจาก Bounding Box ที่รวมรากฟัน ทำให้สามารถรักษาสมดุลของระบบไว้ได้ดีที่สุด จึงถูกคัดเลือกให้เป็น "แบบจำลองที่ดีที่สุด (Final Model)" สำหรับโครงการนี้

```

===== CONFUSION MATRIX [Method 8] =====
      Occlusal  Mesial  Distal  Other
Occlusal      78    121    152    37
Mesial         5    555     80    30
Distal        31     80    763    47


===== CLASSIFICATION REPORT [Method 8] =====
      precision    recall  f1-score   support

      Occlusal      0.68      0.20      0.31       388
       Mesial      0.73      0.83      0.78       670
       Distal      0.77      0.83      0.80       921
        Other      0.00      0.00      0.00         0

   accuracy              0.71       1979
  macro avg              0.55      0.46      0.47       1979
 weighted avg              0.74      0.71      0.70       1979

```

ภาพที่ 30 Classification Report ของ Method 8: X-Thirds Dominant Zone



ภาพที่ 31 Evaluation ของ Method 8: X-Thirds Dominant Zone

4.4.2 Method 9: Diagonal-from-Centroid

4.4.2.1 ผลการจำแนก: Accuracy: 60.28% | Macro F1-score: 0.4601


4.4.2.2 การวิเคราะห์: โมเดลนี้ใช้เส้นทแยงมุมในการแบ่งโซน ซึ่งช่วยเพิ่มความสามารถในการดักจับ (Recall) รอยผุด้าน Occlusal ได้ดีเยี่ยม อย่างไรก็ตาม เกิดภาวะ **Trade-off** อย่าง

รุนแรงกับคลาสด้าน Distal เนื่องจากการที่ Bounding Box ครอบคลุมไปถึงพื้นที่รากฟัน ทำให้พื้นที่สามเหลี่ยมด้านข้างแคบลง รอยผู้ด้านประชิดจึงถูกทำนายผิดเป็น Occlusal จำนวนมาก

===== CONFUSION MATRIX [Method 9] =====				
	Occlusal	Mesial	Distal	Other
Occlusal	269	43	39	37
Mesial	211	386	43	30
Distal	307	29	538	47

===== CLASSIFICATION REPORT [Method 9] =====				
	precision	recall	f1-score	support
Occlusal	0.34	0.69	0.46	388
Mesial	0.84	0.58	0.68	670
Distal	0.87	0.58	0.70	921
Other	0.00	0.00	0.00	0
accuracy			0.60	1979
macro avg	0.51	0.46	0.46	1979
weighted avg	0.76	0.60	0.65	1979

ภาพที่ 32 Classification Report ของ Method 9: X- Diagonal-from-Centroid



ภาพที่ 33 Evaluation ของ Method 9: X- Diagonal-from-Centroid

(หมายเหตุ: Method 5: Furthest Point Alignment และ Method 7: Multi-Class Segmentation ถูกพิจารณาในเชิงทฤษฎีเท่านั้น เนื่องจากพบว่ามีค่าความอ่อนไหวต่อข้อมูลขยะสูงและเกินขอบเขตของข้อมูลที่มีอยู่ จึงไม่นำมาทดสอบเป็นโมเดลจำแนกผลในขั้นตอนนี้)

ตารางที่ 3: ตารางเปรียบเทียบผลลัพธ์กลุ่มแบบจำลองที่เน้นการปรับแนวแกนอ้างอิง (Axis Models)

	Support Case (Total)	Accuracy	Precision	Recall	F1 score
Method 1 PCA OpenCV (Baseline)	1743	0.319	0.42	0.42	0.30
Method 2 Conditional Ratio	1743	0.397	0.55	0.47	0.40
Method 3 Maximum Projected Span	1743	0.398	0.55	0.47	0.40
Method 4 Split-Centroid Anatomy	1743	<u>0.399</u>	0.55	<u>0.47</u>	<u>0.41</u>
Method 6 Absolute Vertical Prior	1743	0.393	<u>0.56</u>	0.46	0.40

ตารางที่ 4: กลุ่มแบบจำลองที่เน้นตรรกะการแบ่งพื้นที่ (Zoning Models)

	Support Case (Total)	Accuracy	Precision	Recall	F1 score	หมายเหตุ
Method 8 X Third Dominant Zone	1979	0.70	0.73 (0.48)	0.62 (0.46)	0.63 (0.47)	Best overall balance
Method 9 Diagonal-from-Centroid (4-triangle zone split)	1979	0.60	0.68 (0.49)	0.62 (0.46)	0.61 (0.46)	Occlusal ดีขึ้น, Distal ลดลง

(หมายเหตุ: ในวงเล็บสีแดงมีการคำนวณ 4 คลาส (Occlusal, Mesial, Distal และ other จึงทำให้ผลออกมาลดลง)

4.5 ผลลัพธ์และการวิเคราะห์เชิงลึก

จากผลการประเมินและการทดสอบทางสถิติในขั้นตอนก่อนหน้า คณะผู้จัดทำได้วิเคราะห์ผลลัพธ์เชิงลึก โดยเปรียบเทียบระหว่างวิธีการหลัก (X-Thirds Dominant Zone) กับวิธีอื่น ๆ เพื่อให้เกิดความเข้าใจถึงสาเหตุของความสำเร็จและข้อจำกัดของระบบจำแนกพื้นผิวฟันผุ โดยเน้นการเปรียบเทียบเชิงลึกระหว่างสองแนว

ทางหลัก ได้แก่ X-Thirds Dominant Zone และ Diagonal-from-Centroid ผ่านการทดสอบทางสถิติ เพื่อตัดสินใจเลือกแบบจำลองที่ดีที่สุด (Final Model) สำหรับการใช้งานจริง

4.5.1 ประสิทธิภาพของแบบจำลอง (Overall Performance Summary)

ผลการประเมินประสิทธิภาพเชิงตัวเลขของแบบจำลองทั้งสอง แสดงได้ดังตารางที่ 5

ตารางที่ 5: เปรียบเทียบค่าความแม่นยำและค่า F1-score ของแบบจำลอง

Model	Accuracy	Macro F1-score
X-Thirds Dominant Zone	0.7054	0.4714
Diagonal-from-Centroid	0.6028	0.4601

จากการสังเกตเบื้องต้น พบว่าวิธี X-Thirds ให้ค่าความแม่นยำรวมสูงกว่าถึง 10.26% อย่างไรก็ตาม ส่วนต่างของค่า Macro F1-score กลับมีความแตกต่างกันเพียงเล็กน้อย (0.0113) ซึ่งนำไปสู่การทดสอบทางสถิติในหัวข้อถัดไป

4.5.2 การทดสอบสมมติฐานทางสถิติ (Statistical Hypothesis Testing)

มีการทดสอบสถิติ 2 รูปแบบ เพื่อวิเคราะห์ความแตกต่างของโมเดลในมิติที่หลากหลาย:

4.5.2.1 การวิเคราะห์ Macro F1-score ด้วย Bootstrap Resampling

เนื่องจาก F1-score ไม่มีการแจกแจงแบบปกติ (Non-parametric) คณะผู้จัดทำจึงใช้เทคนิค Bootstrap Resampling เพื่อสร้างช่วงความเชื่อมั่น:

4.5.2.1.1 สมมติฐานหลัก (H0) ประสิทธิภาพเฉลี่ยทุกคลาส (Macro F1) ของทั้งสองโมเดลไม่แตกต่างกัน

4.5.2.1.2 ผลการทดสอบ พบช่วงความเชื่อมั่น 95% (95% CI) อยู่ที่ [-0.0091, 0.0307] และค่า P-value เท่ากับ 0.2820

4.5.2.1.3 การตีความ เนื่องจากช่วงความเชื่อมั่นครอบคลุมค่าศูนย์ และ P-value > 0.05 จึงยอมรับสมมติฐานหลัก (H0) สรุปได้ว่าในแง่ของ Macro F1-score แบบจำลองทั้งสองมีประสิทธิภาพเทียบเท่ากันเมื่อพิจารณาทุกคลาสอย่างเท่าเทียม

4.5.2.2 การวิเคราะห์ความแม่นยำด้วย Two-Proportion Z-Test

$$Z = \frac{p_1 - p_2}{\sqrt{p(1-p) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

เพื่อทดสอบว่าความแม่นยำที่ต่างกัน 10% เกิดจากความบังเอิญหรือไม่:

4.5.2.2.1 ผลการทดสอบ ค่าสถิติ Z เท่ากับ 6.7837 และค่า P-value 1.17×10^{-11}

4.5.2.2.2 การตีความ P-value มีค่าน้อยกว่า 0.05 อย่างมีนัยสำคัญยิ่ง สรุปได้ว่าวิธี X-Thirds มีความแม่นยำรวมสูงกว่าวิธี Diagonal อย่างแท้จริง ไม่ได้เกิดจากความแปรปรวนของข้อมูลสุ่ม

4.5.3 การวิเคราะห์ข้อผิดพลาด (Error Analysis)

การที่ค่า F1 สู้กันแต่ Accuracy ต่างกันมาก เป็นผลมาจาก **ความไม่สมดุลของคลาส (Class Imbalance)** โดยวิธี Diagonal พยายามเพิ่มค่า Recall ในคลาสกลุ่มน้อย (Occlusal) แต่ต้องแลกมาด้วยความผิดพลาดที่รุนแรงในคลาสกลุ่มใหญ่ (Distal)

4.5.4 การวิเคราะห์สาเหตุหลัก (Root Cause Analysis)

ปัญหาทางเรขาคณิตที่พบคือ **"ขอบเขตภาพที่รวมพื้นที่รากฟัน (Elongated Bounding Box)"** ส่งผลกระทบต่อวิธี Diagonal ดังนี้:

4.5.4.1 Centroid Displacement เมื่อ Bounding Box คลุมถึงราก จุดศูนย์กลาง (Centroid) จะถูกดึงให้ต่ำกว่าตำแหน่งที่ควรจะเป็นตามกายวิภาค

4.5.4.2 Geometric Distortion การตีเส้นทแยงมุมจากจุดศูนย์กลางที่ต่ำเกินไป ทำให้โซน Occlusal ขยายใหญ่ผิดปกติ ในขณะที่โซน Distal ถูกบีบจนแคบเกินไป

4.5.4.3 Misclassification รอยผุด้านประชิด (Distal) จึงมักจะตกไปอยู่ในโซน Occlusal ส่งผลให้ความแม่นยำในคลาส Distal ลดลงอย่างเห็นได้ชัด

4.5.5 การตัดสินใจเลือกแบบจำลองสุดท้าย (Final Model Decision)

จากการเปรียบเทียบกับหลักสถิติและการวิเคราะห์เชิงโครงสร้าง คณะผู้จัดทำตัดสินใจเลือก **X-Thirds Dominant Zone** เป็นแบบจำลองขั้นสุดท้าย (Final Model) ด้วยเหตุผลดังนี้:

4.5.5.1 ความเหนือกว่าทางสถิติ มีค่าความแม่นยำรวม (Accuracy) สูงกว่าอย่างมีนัยสำคัญทางสถิติ ($P < 0.001$)

4.5.5.2 ความสมดุล (Balance) แม้จะให้ Recall ในคลาส Occlusal น้อยกว่า แต่สามารถรักษาสัมรรถนะโดยรวมของระบบไม่ให้เกิดข้อเสียที่รุนแรงในคลาสอื่นๆ

ดังนั้น วิธี **X-Thirds Dominant Zone** จึงเป็นแนวทางที่เหมาะสมที่สุดในการนำไปประยุกต์ใช้เพื่อพัฒนาเป็นระบบสนับสนุนการตัดสินใจสำหรับทันตแพทย์ในลำดับต่อไป

บทที่ 5

บทสรุป

ด้วยข้อเสนอแนะและแนวทางการพัฒนาที่กล่าวมาในส่วนก่อนหน้า สามารถสรุปได้ว่าโครงงานนี้ไม่เพียงสร้างระบบจำแนกพื้นผิวฟันผุที่ใช้ได้จริงเท่านั้น แต่ยังเป็นรากฐานที่สำคัญสำหรับการพัฒนางานวิจัยด้าน Computer Vision ในงานทันตกรรมต่อไป


โครงงานนี้มีวัตถุประสงค์เพื่อพัฒนาและประเมินประสิทธิภาพของระบบจำแนกตำแหน่งพื้นผิวฟันผุ (Caries Surface Classification) จากภาพเอกซเรย์พาโนรามา โดยใช้ Hybrid Framework ที่ผสาน Deep Learning สำหรับการตรวจจับและแยกส่วนฟัน (Tooth Detection & Segmentation) กับ Rule-based Geometric Analysis สำหรับการจำแนกพื้นผิวฟันผุออกเป็น Occlusal, Mesial และ Distal จากการทดลองหลายแนวทาง การวิเคราะห์ข้อผิดพลาด และการทดสอบทางสถิติ ทำให้ได้มาซึ่ง **Best Framework** (ดูได้จากภาพที่ 41) ดังนี้:

1. **Caries ROI Mask Intersection/Overlap** เพื่อหา Pixel ฟันผุและ Tooth ID
2. **PCA (Principal Component Analysis)** เพื่อหาแกนฟัน
3. **Surface Classification** ด้วย **X-Thirds Dominant Zone** (สัดส่วน 40:20:40 สำหรับ Mesial : Occlusal : Distal)

เมื่อนำ **Best Framework** ไปประเมินกับชุดข้อมูลทั้งหมดจำนวน 1,979 ตัวอย่าง พบว่า **X-Thirds Dominant Zone** ให้ผลลัพธ์ที่ดีที่สุด โดยมีความแม่นยำรวม (Accuracy) อยู่ที่ 70.54% และ **Macro F1-Score 0.4714** การทดสอบทางสถิติด้วย Two-Proportion Z-Test และ Bootstrap Resampling ยืนยันว่าวิธีนี้มีประสิทธิภาพโดยรวมเหนือกว่าแนวทางอื่น ๆ อย่างมีนัยสำคัญทางสถิติ โดยเฉพาะภายใต้สภาวะ Class Imbalance ที่รุนแรง

โครงงานนี้พิสูจน์ให้เห็นว่า **Rule-based Geometric Logic** ที่ออกแบบมาอย่างรัดกุมสามารถสร้างระบบที่ **มีประสิทธิภาพ** (Lightweight), **เข้าใจง่าย** (Interpretable) และเหมาะสมกับลักษณะข้อมูลภาพทางทันตกรรมได้เป็นอย่างดี แม้จะยังมีข้อจำกัดด้านคุณภาพ Segmentation และความไม่สมดุลของข้อมูล

Best Performance Framework



ภาพที่ 34 แสดง Best Framework หรือเส้นทางการดำเนินที่ดีที่สุดตั้งแต่ต้นถึงปลายทาง

5.1 ข้อจำกัดและความท้าทายของโครงการ (Limitations & Challenges)

โครงการนี้ยังมีข้อจำกัดด้านลักษณะของข้อมูลและวิธีการวิเคราะห์เชิงเรขาคณิต โดยฟันบางซี่มีรูปร่างไม่สมมาตร มีการซ้อนทับกัน หรือมีขอบฟันที่ไม่ชัดเจน ส่งผลต่อการคำนวณแนวแกนฟันและการแบ่งโซนพื้นผิวฟันในบางกรณี

นอกจากนี้ ชุดข้อมูลยังมีปัญหา Class Imbalance โดยคลาส Occlusal มีจำนวนข้อมูลน้อยกว่าคลาส Mesial และ Distal อย่างชัดเจน ทำให้การจำแนกคลาส Occlusal มีความยากและเกิดความคลาดเคลื่อนสูงกว่าคลาสอื่น

อีกข้อจำกัดสำคัญคือ วิธีการจำแนกพื้นผิวฟันของโครงการเป็น Rule-based Geometric Analysis ซึ่งอาศัยเงื่อนไขเชิงเรขาคณิตและการแบ่งโซนของฟัน จึงยังมีข้อจำกัดในการรองรับลักษณะรูปร่างฟันที่มีความซับซ้อนสูงในบางกรณี

5.2 ข้อเสนอแนะและแนวทางการพัฒนาต่อ (Recommendations & Future Improvements)

ในอนาคต ควรปรับปรุงกระบวนการวิเคราะห์รูปร่างฟันและแนวแกนฟันให้สามารถรองรับฟันที่มีลักษณะซับซ้อนหรือผิดปกติได้ดียิ่งขึ้น เพื่อลดความคลาดเคลื่อนของการแบ่งโซนพื้นผิวฟัน ควรเพิ่มจำนวนข้อมูลของคลาส Occlusal และปรับสมดุลของชุดข้อมูล เพื่อช่วยให้การประเมินผลมีความสมดุลและลด Class Imbalance

นอกจากนี้ อาจพัฒนาแนวทาง Hybrid ที่ผสมระหว่าง Rule-based Analysis และ Machine Learning หรือ Deep Learning สำหรับขั้นตอน Surface Classification โดยตรง เพื่อช่วยให้ระบบสามารถเรียนรู้รู้ลักษณะเชิงพื้นที่ของรอยผู้ได้ละเอียดยิ่งและยืดหยุ่นมากขึ้น รวมถึงควรมีการประเมินผลด้วยชุดข้อมูลที่หลากหลายมากขึ้น และใช้การแบ่งข้อมูลในระดับภาพ (Image-level Split) เพื่อช่วยเพิ่มความน่าเชื่อถือของผลการทดลองในอนาคต

บรรณานุกรม

- [1] G. V. Black, A Work on Operative Dentistry. 1908. [Online]. Available: <https://archive.org/details/workonoperatived01blac>
- [2] T. H. Bui et al., “Deep fusion feature extraction for caries detection on dental panoramic radiographs,” *Applied Sciences*, vol. 11, no. 5, p. 2005, 2021, doi: 10.3390/app11052005.
- [3] L. Lian et al., “Deep learning for caries detection and classification in panoramic radiographs,” *Diagnostics*, vol. 11, no. 9, p. 1672, 2021, doi: 10.3390/diagnostics11091672.
- [4] E. Asci, A. Yilmaz, and K. Kamburoglu, “Deep learning approach to automatic tooth caries segmentation in panoramic radiographs,” *Children*, vol. 11, no. 6, p. 690, 2024, doi: 10.3390/children11060690.
- [5] FDI World Dental Federation, “FDI tooth numbering system.” Accessed: May 8, 2026. [Online]. Available: <https://www.fdiworldddental.org/resources/tooth-numbering-systems>
- [6] G. Litjens et al., “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017, doi: 10.1016/j.media.2017.07.005.
- [7] D. Shen, G. Wu, and H.-I. Suk, “Deep learning in medical image analysis,” *Annual Review of Biomedical Engineering*, vol. 19, pp. 221–248, 2017, doi: 10.1146/annurev-bioeng-071516-044442.
- [8] D. V. Tuzoff et al., “Tooth detection and numbering in panoramic radiographs using convolutional neural networks,” *Dentomaxillofacial Radiology*, vol. 48, no. 4, p. 20180051, 2019, doi: 10.1259/dmfr.20180051.
- [9] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2015, pp. 234–241. [Online]. Available: <https://arxiv.org/abs/1505.04597>

- [10] I. S. Bayrakdar et al., “Deep-learning approach for caries detection and segmentation on dental bitewing radiographs,” *Oral Radiology*, vol. 38, pp. 1–9, 2022, doi: 10.1007/s11282-021-005779.
- [11] Y.-S. Lim et al., “Dual convolutional neural network framework for segmenting dental caries in panoramic radiographs,” *The Journal of Prosthetic Dentistry*, early access, 2026, doi: 10.1016/j.prosdent.2025.09.040.
- [12] I. T. Jolliffe and J. Cadima, “Principal component analysis: A review and recent developments,” *Philosophical Transactions of the Royal Society A*, vol. 374, no. 2065, p. 20150202, 2016, doi: 10.1098/rsta.2015.0202.
- [13] GitHub Repository – Dental Caries Detection. [Online]. Available: <https://github.com/pichitchaipae/dental-caries-detection>

ภาคผนวก

ตารางที่ 6: สรุปงานวิจัยที่เกี่ยวข้อง

กลุ่มงานวิจัย	อ้างอิง	ความเกี่ยวข้องกับ โครงงาน	ข้อจำกัด/ช่องว่างที่ โครงงานนี้ต่อยอด
Caries detection / segmentation จากภาพรังสีทันตกรรม	[2]-[4], [10]-[11]	เป็นพื้นฐานของการตรวจจับและแยกส่วนรอยผุ	ส่วนใหญ่ยังเน้นการตรวจจับหรือ segmentation ไม่ได้จำแนกพื้นผิว Occlusal / Mesial / Distal
Panoramic Radiograph-based caries analysis	[2]-[4], [11]	เกี่ยวข้องโดยตรงกับชนิดข้อมูลที่ใช้ในโครงงาน	ยังมีความท้าทายจากภาพซ้อนทับ ความละเอียด และแนวพื้นที่แตกต่างกัน
Tooth detection / tooth numbering	[8]	ใช้เป็นพื้นฐานในการระบุ Tooth ID และจับคู่รอยผุกับฟันแต่ละซี่	ยังไม่ได้วิเคราะห์ถึงระดับพื้นผิวของรอยผุ
Medical image analysis with Deep Learning	[6], [7]	สนับสนุนแนวคิดการใช้ Deep Learning ในภาพทางการแพทย์	เป็นกรอบทฤษฎีทั่วไป ไม่ได้เฉพาะเจาะจงกับ surface classification ของฟันผุ
Biomedical image segmentation / U-Net	[9]	เป็นพื้นฐานของ segmentation ระดับพิกเซล	ไม่ได้ออกแบบเฉพาะสำหรับการจำแนกพื้นผิวฟันผุ
Caries detection / segmentation จากภาพรังสีทันตกรรม	[2]-[4], [10]-[11]	เป็นพื้นฐานของการตรวจจับและแยกส่วนรอยผุ	ส่วนใหญ่ยังเน้นการตรวจจับหรือ segmentation ไม่ได้จำแนกพื้นผิว Occlusal / Mesial / Distal

Panoramic Radiograph-based caries analysis	[2]-[4], [11]	เกี่ยวข้องโดยตรงกับชนิด ข้อมูลที่ใช้ในโครงการ	ยังมีความท้าทายจาก ภาพซ้อนทับ ความ ละเอียด และแนวฟันที่ แตกต่างกัน
--	---------------	--	---